

**INFORME DE ACTIVIDADES EN EL MARCO DEL PROGRAMA:****ALIANZA CIENTÍFICA CON ENFOQUE  
COMUNITARIO PARA MITIGAR BRECHAS DE  
ATENCIÓN Y MANEJO DE TRASTORNOS  
MENTALES RELACIONADOS CON IMPULSIVIDAD  
EN COLOMBIA**

---

Nombre: Julián David Pastrana Cortés

Contrato de servicios: 5551



---

**Grupo de investigación en Automática**

30 de enero de 2026

## Índice

<b>1. Información general del contrato</b>	<b>3</b>
1.1. Descripción general de la vinculación . . . . .	3
1.2. Objetivo general . . . . .	3
<b>2. Metodología</b>	<b>3</b>
2.1. Actividad 1: Planteamiento de la metodología, técnicas y modelos a implementar (Meses 1-2) . . . . .	3
2.2. Actividad 2: Revisión técnica del estado del arte (Meses 3-4) . . . . .	3
2.3. Actividad 3: Desarrollo e implementación de modelos de análisis de EEG (Meses 5-6) . . . . .	4
2.4. Actividad 4: Documentación de resultados consolidados (Meses 6-7) . . . . .	4
<b>3. Resultados</b>	<b>4</b>

## 1. Información general del contrato

<b>Rol</b>	Contratista - Estudiante de Doctorado
<b>Contrato de servicios No.</b>	5533 de 2026
<b>Objeto del contrato</b>	Prestación de servicios profesionales para el Desarrollo de metodología de gamificación para entrenamiento de niños con trastornos de impulsividad ALIANZA CIENTÍFICA CON ENFOQUE COMUNITARIO PARA MITIGAR BRECHAS DE ATENCIÓN Y MANEJO DE TRASTORNOS MENTALES RELACIONADOS CON IMPULSIVIDAD EN COLOMBIA - ACEMATE MINCIENCIAS CONTRATO 790-2023
<b>Período del informe</b>	19 de enero de 2026 al 31 de agosto de 2026

### 1.1. Descripción general de la vinculación

Como resultado de la vinculación se contribuye al alcance de el objetivo 3 del programa de investigación: ALIANZA CIENTÍFICA CON ENFOQUE COMUNITARIO PARA MITIGAR BRECHAS DE ATENCIÓN Y MANEJO DE TRASTORNOS MENTALES RELACIONADOS CON IMPULSIVIDAD EN COLOMBIA

### 1.2. Objetivo general

Desarrollar una metodología de gamificación para entrenamiento de niños con trastornos de impulsividad ALIANZA CIENTÍFICA CON ENFOQUE COMUNITARIO PARA MITIGAR BRECHAS DE ATENCIÓN Y MANEJO DE TRASTORNOS MENTALES RELACIONADOS CON IMPULSIVIDAD EN COLOMBIA - ACEMATE MINCIENCIAS CONTRATO 790-2023.

## 2. Metodología

La metodología propuesta para el desarrollo del proyecto se estructura en cuatro actividades principales, distribuidas a lo largo de siete meses, con entregables específicos para cada una:

### 2.1. Actividad 1: Planteamiento de la metodología, técnicas y modelos a implementar (Meses 1-2)

En esta etapa inicial se realizará la conceptualización y diseño de la metodología de trabajo. Se definirán las técnicas de análisis y los modelos computacionales que se implementarán para el procesamiento de señales EEG. Esta actividad incluye la revisión de fundamentos teóricos, selección de herramientas y establecimiento del marco de trabajo.

**Entregable:** Informe técnico que documenta la metodología propuesta, las técnicas seleccionadas y los modelos a desarrollar.

### 2.2. Actividad 2: Revisión técnica del estado del arte (Meses 3-4)

Se llevará a cabo una revisión exhaustiva y sistemática del estado del arte en análisis de señales EEG, identificando las metodologías existentes, técnicas avanzadas y tendencias actuales en el procesamiento de señales cerebrales. Esta revisión permitirá contextualizar el trabajo y validar las decisiones metodológicas.

**Entregable:** Informe técnico con el análisis del estado del arte y la fundamentación teórica del proyecto.

### 2.3. Actividad 3: Desarrollo e implementación de modelos de análisis de EEG (Meses 5-6)

Esta etapa constituye el núcleo del proyecto, donde se desarrollarán e implementarán los modelos de análisis de señales EEG. Se realizará el montaje y configuración de los modelos para diferentes tareas específicas, incluyendo pruebas, validación y optimización de los algoritmos desarrollados.

**Entregable:** Código fuente de los modelos implementados, documentado y funcional.

### 2.4. Actividad 4: Documentación de resultados consolidados (Meses 6-7)

En la fase final se consolidarán todos los resultados obtenidos durante el proyecto. Se documentarán los hallazgos, análisis de desempeño de los modelos, conclusiones y recomendaciones. Esta documentación servirá como soporte integral del proyecto.

**Entregable:** Informe técnico final con la documentación completa de resultados, análisis y conclusiones del proyecto.

## 3. Resultados

4    **Chapter 1**

5    **Toward a Setup-Agnostic  
6    Strategy for EEG Modeling**

7    **1.1 Datasets**

8    In order to develop and evaluate a setup-agnostic strategy for EEG modeling, we  
9    consider multiple publicly available EEG datasets that vary in terms of number  
10   of channels and sampling rates. The selected datasets include:

- 11    • BCI Competition IV-2a (BCI2a) [1]  
12    • BCI Competition IV-2b (BCI2b) [2]  
13    • GigaScience Motor Imagery EEG Dataset (GigaDB) [3]

The following table summarizes the key characteristics of each dataset:

Dataset	Channels	Sampling Rate (Hz)	Filtering (Hz)	Subjects	Classes	Trials per Sub.
BCI2a	22	250	0.5-100	9	4	288
BCI2b	3	250	0.5-100	9	2	280
GigaDB	64	512	0.5-100	52	2	120

Table 1.1: Summary of EEG datasets used for setup-agnostic modeling. All datasets have balanced class proportions.

14

15    **1.2 Incorporationg Brain Structure via Graph  
16    Neural Networks**

17    Neural Networks models has been widely applied to model a vast variety of  
18    comeplex tasks, comprising data information in a set of parameters. Some

**4CHAPTER 1. TOWARD A SETUP-AGNOSTIC STRATEGY FOR EEG MODELING**

19 architectures owes its sucess to modeling data structure. For instance, Convolutional Neural Networks (CNNs) work well with images-like data placing a set  
20 of local and invariant filters (or kernels) across the spatial dimension of input  
21 data. In the space of all possibles images given a resolution, just a small subset of  
22 them correspond to meaningful images, due a high degree of spatial correlation  
23 and redundancy between nearby pixels. So, local-invariant filters exploit this  
24 property to reduce the number of parameters needed to model images, while  
25 keeping relevant information, improving generalization and reducing overfitting  
26 compared to fully-connected architectures. On the other hand, Recurrent Neural  
27 Networks (RNNs) assume Markovian property over an input sequence data;  
28 past information is summarized in a hidden state parameter and in this way,  
29 next output depends just on current input and hidden state, allowing work with  
30 varying length sequences with a fixed number of parameters. The above motivate  
31 the idea that provide data structure to Neural Network models plays a key  
32 role in their sucess as is the way of how the model interpreteate the information.  
33

34 A widely used models for EEG classification implement CNNs over inputs,  
35 treating EEGs as fixed pseudo-images [4, 5]. However, that overlook channels  
36 spatial distribution and relationships between them. EEG channels are placed  
37 over the scalp in non-uniform distances, and nearby channels tends to be more  
38 correlated than faraway ones. Thus, since EEG exhibit a graph structure, EEG  
39 classification should be done on graphs, not pseudo-images [6].

# <sup>40</sup> Bibliography

- 41 [1] C. Brunner, R. Leeb, G. R. Müller-Putz, A. Schloegl, and G. Pfurtscheller,  
42 “Bci competition 2008 – graz data set a,” *Institute for Knowledge Discovery,*  
43 *Graz University of Technology*, 2008. BCI Competition IV, Dataset 2a.
- 44 [2] R. Leeb, C. Brunner, G. R. Müller-Putz, A. Schloegl, and G. Pfurtscheller,  
45 “Bci competition 2008 – graz data set b,” *Institute for Knowledge Discovery,*  
46 *Graz University of Technology*, 2008. BCI Competition IV, Dataset 2b.
- 47 [3] H. Cho, M. Ahn, S. Ahn, M. Kwon, and S. C. Jun, “Eeg datasets for motor  
48 imagery brain–computer interface,” *GigaScience*, vol. 6, no. 7, pp. 1–8, 2017.
- 49 [4] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung,  
50 and B. J. Lance, “Eegnet: a compact convolutional neural network for eeg-  
51 based brain–computer interfaces,” *Journal of Neural Engineering*, vol. 15,  
52 no. 5, p. 056013, 2018.
- 53 [5] Y. Song, Q. Zheng, B. Liu, and X. Gao, “Eeg conformer: Convolutional  
54 transformer for eeg decoding and visualization,” *IEEE Transactions on Neu-*  
55 *ral Systems and Rehabilitation Engineering*, vol. 31, pp. 710–719, 2023.
- 56 [6] A. Demir, T. Koike-Akino, Y. Wang, M. Haruna, and D. Erdogmus, “Eeg-  
57 gnn: Graph neural networks for classification of electroencephalogram (eeg)  
58 signals,” in *Proceedings of the Annual International Conference of the IEEE*  
59 *Engineering in Medicine and Biology Society, EMBS*, vol. 2021-January,  
60 pp. 1061–1067, Institute of Electrical and Electronics Engineers Inc., 2021.