

INFORME DE ACTIVIDADES EN EL MARCO DEL PROGRAMA:**ALIANZA CIENTÍFICA CON ENFOQUE
COMUNITARIO PARA MITIGAR BRECHAS DE
ATENCIÓN Y MANEJO DE TRASTORNOS
MENTALES RELACIONADOS CON IMPULSIVIDAD
EN COLOMBIA**

Nombre: Julián David Pastrana Cortés

Contrato de servicios: 5551



Grupo de investigación en Automática

4 de diciembre de 2025

Índice

1. Información general del contrato	3
1.1. Descripción general de la vinculación	3
1.2. Objetivo general	3
2. Metodología	3
3. Conjunto de Datos	4
3.1. Toadstool: Un conjunto de datos para el entrenamiento de máquinas de inteligencia emocional que juegan a Super Mario Bros	4
4. Resultados	4
5. Anexos	7
Anexos	7

1. Información general del contrato

Rol	Contratista - Estudiante de Doctorado
Contrato de servicios No.	5551 de 2025
Objeto del contrato	Prestación de servicios profesionales para el Desarrollo de metodología de gamificación para entrenamiento de niños con trastornos de impulsividad ALIANZA CIENTÍFICA CON ENFOQUE COMUNITARIO PARA MITIGAR BRECHAS DE ATENCIÓN Y MANEJO DE TRASTORNOS MENTALES RELACIONADOS CON IMPULSIVIDAD EN COLOMBIA - ACEMATE MINCIENCIAS CONTRATO 790-2023
Período del informe	01 de marzo de 2025 al 31 de marzo de 2025

1.1. Descripción general de la vinculación

Como resultado de la vinculación se contribuye al alcance de el objetivo 3 del programa de investigación: ALIANZA CIENTÍFICA CON ENFOQUE COMUNITARIO PARA MITIGAR BRECHAS DE ATENCIÓN Y MANEJO DE TRASTORNOS MENTALES RELACIONADOS CON IMPULSIVIDAD EN COLOMBIA

1.2. Objetivo general

Desarrollar una metodología de gamificación para entrenamiento de niños con trastornos de impulsividad ALIANZA CIENTÍFICA CON ENFOQUE COMUNITARIO PARA MITIGAR BRECHAS DE ATENCIÓN Y MANEJO DE TRASTORNOS MENTALES RELACIONADOS CON IMPULSIVIDAD EN COLOMBIA - ACEMATE MINCIENCIAS CONTRATO 790-2023.

2. Metodología

Para llevar a cabo el objetivo general planteado, se plantean las siguientes etapas:

- Etapa 1: Revisión del estado del arte sobre gamificación y trastorno de impulsividad para identificar las mejores prácticas y metodologías existentes.
- Etapa 2: Desarrollo de una metodología preliminar de gamificación.
- Etapa 3: Redacción y sometimiento de un artículo de investigación en revista indexada, donde se exponga la metodología preliminar desarrollada.
- Etapa 4: Ampliación de la metodología preliminar de gamificación mediante el uso de Procesos Gaussianos.
- Etapa 5: Redacción y sometimiento de un artículo de investigación en revista indexada, donde se exponga la metodología final desarrollada.
- Etapa 6: Elaboración de un informe técnico final sobre el desarrollo y resultados de las actividades.

3. Conjunto de Datos

3.1. Toadstool: Un conjunto de datos para el entrenamiento de máquinas de inteligencia emocional que juegan a Super Mario Bros

El conjunto de datos de libre acceso Toadstool es una colección de registros en video, sensores e información demográfica obtenidos de diez individuos mientras jugaban Super Mario Bros. La selección de los participantes se realizó buscando una amplia variedad en cuanto a experiencia previa con videojuegos, incluyendo desde personas que apenas habían jugado alguno en su vida hasta aquellas con una extensa trayectoria desde la infancia, con edades comprendidas entre los 26 y 48 años. También se buscó mantener un balance en el género, participando cinco hombres y cinco mujeres. Los autores en [Svoren et al., 2020] señalan la presencia de anomalías, tales como ninguna o muy poca actividad detectada por los sensores, así como diferencias significativas entre la actividad registrada al inicio y al final de las sesiones de juego.

El desempeño de los participantes fue evaluado según el número de niveles completados en un tiempo determinado y el número de muertes ocurridas durante la partida. Dicho puntaje se mantuvo en secreto entre los participantes para evitar que se rindieran o relajaran durante el juego. Adicionalmente, se les incentivó mediante una recompensa con el fin de mantener un desempeño competitivo. Un resumen de las características de los participantes se presenta en la Tabla 1.

ID	Edad	Sexo	Mano dominante	Horas por semana	Años de actividad	Experiencia previa	Puntaje del juego
0	26	Hombre	Derecha	4–8	22	Mucha	17,100
1	48	Hombre	Izquierda	0–1	1	Poca	3,000
2	28	Hombre	Derecha	0–1	0	Ninguna	300
3	32	Hombre	Derecha	4–8	4	Algo	13,300
4	32	Mujer	Derecha	0–1	5	Algo	6,400
5	30	Mujer	Derecha	0–1	5	Poca	2,700
6	35	Hombre	Izquierda	1–4	30	Mucha	14,300
7	34	Mujer	Derecha	1–4	14	Algo	3,800
8	31	Mujer	Derecha	0–1	2	Poca	200
9	27	Mujer	Derecha	0–1	5	Poca	10,600

Tabla 1: Características demográficas y experiencia de los participantes en relación con su desempeño en el juego. Se incluyen datos como edad, sexo, lateralidad, dedicación semanal, años de experiencia, nivel de experiencia previa y puntaje obtenido.

En el conjunto de datos, se incluye para cada participante un video de su rostro durante la sesión de juego, grabado a una resolución de 640×480 píxeles y a 30 fotogramas por segundo. Además, se registran las acciones realizadas mediante el mando de juego para controlar al personaje, así como los datos recopilados por la pulsera Empatica E4. La Empatica E4 es un dispositivo que permite la adquisición en tiempo real de datos fisiológicos, como la actividad electrodérmica (EDA), el pulso de volumen sanguíneo (BVP), la temperatura de la piel y la aceleración en tres ejes [Garbarino et al., 2014].

4. Resultados

Se presenta la versión definitiva de la propuesta de doctorado sobre modelos funcionales y procesos Gaussianos aplicados a la detección y tratamiento de trastornos mentales, documentada en la sección de anexos.

Se implementó en Python un modelo de inferencia basado en procesos Gaussianos encadenados para ampliar la metodología de gamificación mediante un enfoque estocástico.

El conjunto de datos Toadstool 2 fue seleccionado por su variedad en datos provenientes de múltiples fuentes, cada una con sus propios parámetros de adquisición, registrados dentro de una ventana de 4 segundos. Todos los datos recolectados durante este intervalo fueron etiquetados con una emoción, pudiendo ser enojado, neutro, triste, sorprendido, entre otras.

El problema del conjunto de datos anterior puede abordarse como uno de fusión asincrónica de múltiples fuentes. Una revisión del estado del arte resalta a las redes recurrentes como candidatas para construir un mo-

delo que integre y explote datos temporales, con el fin de generar una representación latente que condense las características más importantes de las secuencias en un conjunto finito de variables. Finalmente, esta representación será la encargada de alimentar el modelo basado en procesos Gaussianos para generar una distribución predictiva como pronóstico.

Se desarrolló e implementó un modelo basado en redes neuronales recurrentes LSTM que alternan sus celdas ocultas dependiendo de las características y del número de entradas, manteniendo sus estados latentes y memorias compartidas, llamado Multi-Rate LSTM, como se muestra en la Figura 1. Aquí un tipo particular de celda se encarga de analizar una configuración de entrada en cada instante de tiempo, actualizar los estados ocultos y posteriormente transferir la información relevante a la siguiente celda en el siguiente instante de tiempo.

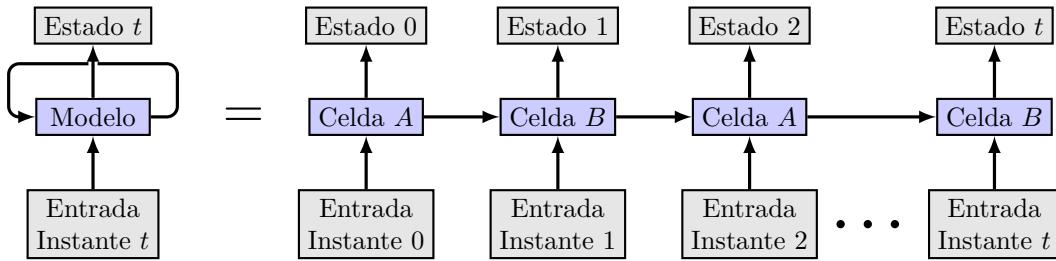


Figura 1: Representación gráfica del modelo Multi-Rate LSTM.

Sin embargo, la realización de varias pruebas mostró que el conjunto de datos Toadstool 2 presenta un desbalance entre el número de muestras disponibles y la complejidad de predecir etiquetas basadas en datos provenientes de múltiples fuentes.

Para solucionar este problema, se está integrando un nuevo conjunto de datos denominado EPA-air, el cual incluye mediciones ambientales detalladas provenientes de múltiples sensores distribuidos geográficamente, proporcionando información temporal y multimodal que facilita la sincronización y el análisis de secuencias temporales para apoyar el entrenamiento del modelo.

Se identificó como problema latente en las técnicas de gamificación la integración asincrónica de múltiples fuentes. El problema radica en cómo mantener las dependencias a lo largo de las series de tiempo y entre las mismas, a pesar de la asincronía de adquisición, presente cuando a un paciente se le toman múltiples métricas provenientes de diferentes dispositivos.

Se propone el uso de parches de longitud variable para mantener la secuencialidad de los datos ante este escenario. Esto alimenta un modelo secuencial, como una red LSTM, para generar un espacio embebido que posteriormente será mapeado al espacio de salida mediante un modelo probabilístico.

Una revisión profunda del estado del arte evidencia el uso de modelos basados en redes convolucionales y arquitecturas transformer, capaces de capturar características temporales y espaciales a nivel local y global. En esta línea, se han implementado modelos EEGNet y EEG Conformer para el análisis de señales EEG, las cuales registran la actividad eléctrica cerebral mediante electrodos sobre el cuero cabelludo. Estos modelos han mostrado resultados satisfactorios con la base de datos BCI Competition IV 2a, que contiene registros multicanal de EEG durante tareas de imaginación motora. Actualmente, se realizan pruebas con una base de datos propia orientada a la clasificación de estados de inhibición y no inhibición, con el fin de evaluar la robustez y capacidad de generalización del modelo.

Se implementó un modelo basado en la arquitectura NeuroGPT, el cual se divide en un encoder EEG Conformer y un decoder GPT-2. Se están realizando pruebas con diferentes configuraciones para abarcar el problema de clasificación de señales EEG en tareas de inhibición y no inhibición y TDAH y control. Las pruebas realizadas con la base de datos BCI Competition IV 2a han logrado resultados desempeños competitivos con los modelos del estado del arte.

Se están realizando pruebas con la base de datos IEE EEG data for ADHD / Control children. Un primer problema ha sido adaptar el modelo pre entredado con EEGs de 40 canales a los 19 canales de la base de datos IEE. Como estrategia de solución, se ha optado por realizar una nueva etapa de pre entrenamiento con una configuración apropiada de canales.

Problem Statement We model a EEG signal as a multichannel time series, where each channel corresponds to an electrode placed on the scalp $\mathcal{X} \in \mathbb{R}^{C \times M}$, with C being the number of channels and M the number of time points. We split the signal into overlapping segments of length T with a stride of S , resulting in $N = \frac{M-T}{S} + 1$

segments. Given a set of EEG recordings for different subjects, we create the set $\mathcal{D} = \{(\mathbf{X}_i^p, y_i^p)\}_{p,i=1}^{P,N}$, where $\mathbf{X}_i^p \in \mathbb{R}^{C \times T}$ is the i -th segment of the p -th subject's EEG signal, and y_i^p is the corresponding label indicating the cognitive state (e.g., inhibition or non-inhibition). The objective is to learn a mapping function $f : \mathbb{R}^{C \times T} \rightarrow \mathcal{Y}$, where \mathcal{Y} is the set of possible cognitive states, that can accurately classify unseen EEG segments based on their learned representations.

5. Anexos

Propuesta de Integración de Modelos Fundacionales y Procesos Gaussianos para el Apoyo al Diagnóstico y Tratamiento de Trastornos Mentales a partir de Señales Electroencefalográficas .

Julián David Pastrana Cortés, M.Sc.

Resumen

El diagnóstico de trastornos mentales y algunas terapias tradicionalmente se basan en evaluaciones clínicas, entrevistas y pruebas estandarizadas, lo cual puede conllevar interpretaciones subjetivas y requerir un seguimiento prolongado. Además, la generación de modelos de inteligencia artificial que apoyen la práctica clínica suele depender de grandes volúmenes de datos etiquetados, restringe su trasferencia a ambientes reales. En este contexto, el presente proyecto propone el desarrollo de un modelo fundacional estocástico basado en procesos Gaussianos para el entrenamiento de modelos de Inteligencia Artificial (IA) a partir de múltiples bases de datos de señales electroencefalográficas (EEG) con características de adquisición variantes, que integre datos no etiquetados mediante técnicas de autoaprendizaje y datos etiquetados para su ajuste fino. Este enfoque no solo busca extraer representaciones generales a partir de la estructura de las señales biológicas, sino que también incorpora un componente que modela la incertidumbre en las predicciones, ofreciendo una medida cuantitativa de la confiabilidad del modelo. Se espera que los resultados impulsen la generación de nuevo conocimiento y la innovación en los ámbitos de la salud, la ingeniería y la ciencia.

Abstract

The diagnosis of mental disorders and certain therapies have traditionally relied on clinical evaluations, interviews, and standardized tests, which can lead to subjective interpretations and require prolonged follow-up. Moreover, the development of artificial intelligence models that support clinical practice typically depends on large volumes of labeled data, limiting their transfer to real-world settings. In this context, the present project proposes the development of a stochastic foundational model based on Gaussian processes for training AI models using multiple databases of electroencephalographic (EEG) signals with varying acquisition characteristics. This model integrates unlabeled data through self-learning techniques and labeled data for fine-tuning. This approach not only seeks to extract general representations from the structure of biological signals but also incorporates a component that models prediction uncertainty, providing a quantitative measure of the model's reliability. It is expected that the results will spur the generation of new knowledge and innovation in the fields of health, engineering, and science.

1. Planteamiento del problema y pregunta de investigación

Los trastornos mentales afectan la cognición, el comportamiento y las emociones de millones de personas en el mundo. Se estima que alrededor de 350 millones de individuos padecen algún trastorno mental [1]. La impulsividad, como característica sintomática central, está presente en diversas condiciones mentales, entre las que destacan el Trastorno Negativista Desafiant (TND), el Trastorno de Desregulación del Estado de Ánimo Disruptivo (TDEAD) y el Trastorno Bipolar (TB). Dentro de este grupo, el Trastorno por Déficit de Atención e Hiperactividad (TDAH) representa un desafío clínico significativo, con una prevalencia aproximada del 5% en población infantil y adolescente, y del 2.5% en adultos, constituyendo así uno de los trastornos neuropsiquiátricos más comunes durante la infancia y la adolescencia.

Estos trastornos no solo dificultan el rendimiento académico y laboral [2], sino que también aumenta el riesgo de presentar otros problemas psiquiátricos, conductas delictivas y adicciones [3].

La detección e intervención temprana de la impulsividad es esencial para brindar un tratamiento oportuno y efectivo [4]. Sin embargo, las técnicas diagnósticas actuales presentan limitaciones importantes: muchas pruebas requieren un seguimiento prolongado [5], pueden estar sujetas a interpretaciones subjetivas [6], omitirse debido a la gran variación en las presentaciones clínicas y síntomas [7], y muchos criterios resultan inefficientes para el diagnóstico en adultos [8]. Además, el acceso a un tratamiento clínico y seguimiento es frecuentemente restringido debido a la falta de recursos o la escasez de especialistas [9, 10].

El avance en el desarrollo de modelos de aprendizaje automático ha permitido la creación de herramientas que apoyan el diagnóstico y tratamiento de diversas enfermedades neurológicas y trastornos mentales [11]. Generalmente, estos modelos utilizan señales electroencefalográficas (EEG) para clasificar registros según la presencia o ausencia de la enfermedad, mediante un enfoque de clasificación binaria. No obstante, la naturaleza no estacionaria y la complejidad inherente a las señales EEG complican su análisis utilizando modelos tradicionales [12, 13].

El uso de técnicas de aprendizaje profundo se presenta como una alternativa prometedora, ya que permite extraer características abstractas de las señales EEG mediante una gran cantidad de parámetros [14, 15, 16]. No obstante, el entrenamiento de estos modelos demanda grandes volúmenes de datos etiquetados en un entorno supervisado, lo cual frecuentemente es costoso o inviable, y su potencial mejora se ve limitada por la falta de interpretabilidad [17, 18].

Para superar esta limitación, han surgido los modelos fundacionales, que permiten preentrenar con conjuntos de datos no etiquetados y, posteriormente, ajustar el modelo para tareas específicas utilizando una cantidad significativamente menor de datos etiquetados [19, 20]. Este enfoque aprovecha la estructura subyacente presente en datos sin clasificar, permitiendo que el modelo aprenda representaciones generales robustas. Gracias a este preentrenamiento, el modelo puede transferir conocimientos a tareas concretas, lo que reduce la dependencia de grandes volúmenes de datos anotados y agiliza el proceso de adaptación a nuevos escenarios.

Un aspecto relevante en el preentrenamiento de estos modelos es la variabilidad inherente a los conjuntos de datos no etiquetados. Estas bases de datos pueden diferir en los estándares de adquisición, lo que se manifiesta en la presencia de valores ausentes, variaciones en la tasa de muestreo, diferencias en el número de canales e incluso problemas de generalización al cambiar de sujetos o sesiones (conocido como Dataset Shift) [21]. Descartar estos datos supondría la pérdida de información potencialmente valiosa; por ello, es importante desarrollar un modelo fundacional capaz de gestionar eficazmente dichas inconsistencias y maximizar el aprovechamiento de los datos disponibles.

Lo anterior también induce una incertidumbre en el modelo, por lo que en el ámbito clínico no es suficiente obtener una predicción puntual en el diagnóstico, sino también disponer de una medida de la incertidumbre asociada que cuantifique el nivel de riesgo a la hora de tomar una decisión basada en la inferencia del modelo. En este sentido, los procesos Gaussianos ofrecen una solución al generar una distribución de probabilidad predictiva mediante un enfoque Bayesiano en lugar de una predicción puntual [22, 14]. Sin embargo, la integración de procesos Gaussianos con modelos fundacionales aún es un área poco explorada y con un gran potencial de mejora.

Pregunta de investigación: ¿Cómo desarrollar un modelo fundacional estocástico para la inferencia a partir de señales biológicas que integre procesos Gaussianos, para el soporte a la práctica clínica mediante el análisis de señales EEG, considerando la variabilidad e inconsistencias presentes en los conjuntos de datos?

2. Justificación

Desde el ámbito de la salud pública, los trastornos mentales son considerados una prioridad mundial debido a sus implicaciones en el desarrollo social. Su presencia está asociada con el fracaso escolar, comportamientos antisociales e incluso delincuencia. Estos presentan subtipos según su gravedad: leve, moderado o grave. Su etiología está relacionada con factores genéticos, neurobiológicos, prenatales, perinatales y posnatales, cuya interacción contribuye a su manifestación clínica [23].

El Plan Nacional de Desarrollo 2022-2026 (PND), Colombia Potencia Mundial de la Vida, busca trabajar mediante un enfoque preventivo y predictivo, estrategias orientadas a promover la capacidad de agencia y cuidado de la salud. En su sección, Salud y bienestar para las juventudes, propone fomentar el bienestar mental, con el objetivo de abordar las causas que inciden en la salud mental de los jóvenes y fomentar las prácticas profesionales que potencien su acompañamiento.

Por su parte, el CONPES 3992 establece estrategias para la promoción de la salud mental, incluyendo la investigación y la integración de sistemas de información en el área. En particular, el Departamento Nacional de Planeación (DNP) desarrolla un modelo predictor de determinantes sociales incidentes en la salud mental para orientar políticas de promoción. Asimismo, el Ministerio de Salud y Protección Social promueve estrategias para la atención en salud e inclusión social.

Solamente la prevalencia mundial del TDAH oscila entre el 5 % y 10 % en niños en edad escolar [24], en Colombia se han reportado valores del 15-17%, ubicándose entre las cifras más altas de Latinoamérica [25]. Se estima que la prevalencia por rango de edad es del 62% en niños entre 6 y 11 años, debido a alteraciones en la maduración cerebral, lo que se traduce en un retraso de entre 2 y 3 años con respecto a niños sin la condición [26].

El diagnóstico de los trastornos mentales se basa en los criterios del DSM-5, a partir de información aportada por el paciente o su entorno sobre síntomas percibidos de inatención, impulsividad e hiperactividad, los cuales deben mantenerse durante al menos seis meses, no ser acordes al nivel de desarrollo y afectar el desempeño social, académico o laboral. Sin embargo, la ponderación subjetiva de los síntomas conlleva restricciones como discrepancias en las percepciones entre padres, maestros y profesionales [27], la variabilidad e inconsistencia en la adopción de guías clínicas y criterios insuficientes del DSM-5 [28, 29]. Además, la cobertura diagnóstica es limitada: solo el 7.4 % de los casos recibe confirmación mediante entrevista psiquiátrica estructurada, y solo el 6.6 % recibe tratamiento [30], lo que genera una alta tasa de diagnósticos erróneos en la población infantil de la región [31].

Paralelamente, se han desarrollado plataformas digitales e interfaces avanzadas para la interacción con pacientes, las cuales pueden facilitar el diagnóstico y tratamiento de diversas patologías. Entre estas, los videojuegos han cobrado relevancia como herramientas asistenciales, debido a su capacidad para mejorar la flexibilidad cognitiva y la memoria de trabajo, aspectos clave en la atención y concentración. La Política Nacional de Ciencia, Tecnología e Innovación 2021–2030 fomenta el desarrollo de tecnologías innovadoras en este ámbito. En este contexto, el grupo de investigación en Automática ha desarrollado un amplio trabajo en áreas relacionadas con el análisis de señales biológicas, el modelado de procesos estocásticos y el aprendizaje automático, con aplicaciones en el ámbito de la salud y los trastornos mentales. Además, cuenta con equipos clínicos especializados para la adquisición y análisis de registros EEG.

En conclusión, es necesario fortalecer los programas de salud mental infantil para detectar a tiempo los factores asociados a los trastornos mentales y mejorar los indicadores de prevalencia. Además, resulta importante optimizar la calidad en el diagnóstico, evaluación e intervención de los pacientes. En este sentido, esta propuesta se enfoca en enfrentar estos desafíos, reconociendo que se trata de un problema de salud pública de gran magnitud, mediante el desarrollo de una herramienta de apoyo para el diagnóstico y tratamiento de trastornos mentales a partir de señales EEG, que no solo contribuya a generar nuevos conocimientos, sino que también impulse la innovación en los sectores de la salud, la ingeniería y la

ciencia.

3. Estado del arte

Diversos modelos de aprendizaje automático han sido propuestos para apoyar el diagnóstico de trastornos mentales, como la esquizofrenia, alzheimer, depresión y autismo [32]. Por ejemplo, en [33] se implementó un modelo basado en un regresor logístico que utiliza la transformada wavelet para la clasificación de registros electroencefalográficos, permitiendo resaltar características relevantes. Asimismo, en [34] se utilizaron máquinas de soporte vectorial, las cuales ofrecen resultados interpretables para orientar las decisiones clínicas. Además, en [35] se presentó un sistema automatizado de clasificación para diferenciar entre diferentes trastornos mentales, utilizando técnicas de descomposición para extraer características discriminatorias.

Por otro lado, en [36] se implementaron modelos de aprendizaje profundo, combinando capas convolucionales y de memoria LSTM, evidenciando su potencial en la evaluación de la esquizofrenia. Además, en [37] se empleó una arquitectura basada en redes neuronales convolucionales, revelando su utilidad en análisis en la depresión y el estado de ánimo. Por último, en [38] se propone una red convolucional profunda para extraer características discriminatorias y distinguir entre dos subtipos de trastornos mentales, logrando una precisión cercana al 99.46 %.

Por su parte, los modelos fundacionales emergen como herramientas de inteligencia artificial preentrenadas a gran escala, capaces de adaptarse a tareas específicas y, en consecuencia, de posibilitar diagnósticos personalizados en el ámbito clínico. En [39] se ilustra un amplio espectro de modelos fundacionales aplicados a la medicina, evidenciando su potencial en aplicaciones de salud basadas en imágenes. Asimismo, en [40] se proponen estos modelos para la clasificación de imágenes provenientes de múltiples fuentes, logrando un rendimiento aceptable y eficiencia en términos de costo para aplicaciones clínicas. Además, en [41] se demuestra que el empleo de aprendizaje auto-supervisado aplicado a grandes volúmenes de datos de fotopletismografía y electrocardiograma permite entrenar modelos fundacionales capaces de extraer información relevante sobre el estado de salud de los usuarios, lo que facilita la detección temprana de la enfermedad y el seguimiento de sus comorbilidades.

Los procesos Gaussianos han sido ampliamente utilizados en diversos estudios para mejorar la precisión en el diagnóstico y la comprensión de los trastornos mentales, aprovechando sus propiedades no paramétricas y estocásticas. Por ejemplo, en [42] se implementó un clasificador basado en este modelo, el cual empleó datos relativos al volumen de la materia gris para discriminar entre individuos sanos, alcanzando una precisión cercana al 79.3 %. De manera similar, en [43] se aplicó un clasificador fundamentado en procesos Gaussianos para predecir el diagnóstico individual de TDAH mediante un análisis de patrones multivariantes durante una tarea de atención, logrando una precisión global del 77 %. Estos resultados han permitido establecer correlaciones entre la severidad de los síntomas y el diagnóstico, contribuyendo a una mejor comprensión de sus manifestaciones clínicas.

4. Objetivos

Objetivo General

Desarrollar una metodología de aprendizaje relacionada con registros EEG basado en un modelo fundamental, que cuantifique la incertidumbre en la inferencia e integre bases de datos etiquetadas y no etiquetadas mediante técnicas de autoaprendizaje y ajuste fino.

Objetivos específicos

1. Desarrollar un modelo fundamental para la clasificación de señales biológicas relacionadas con registros EEG, que aproveche datos no etiquetados en la etapa de autoaprendizaje y datos etiq

tados para su ajuste fino.

2. Implementar una herramienta de predicción estocástica basada en procesos Gaussianos, que permita modelar la incertidumbre en la predicción del modelo fundacional.
3. Diseñar una estrategia para manejar la variabilidad e inconsistencia en conjuntos de datos de registros EEG, permitiendo la integración efectiva de bases de datos con diversos estándares para su aprovechamiento en el modelo.

5. Metodología

Para dar cumplimiento a cada uno de los objetivos específicos, se propone la siguiente metodología, la cual estará dividida en tres fases (una por cada objetivo):

Fase 1: Diseño y Desarrollo del Modelo Fundacional para la Clasificación de Señales EEG

Objetivo específico 1: Diseñar y desarrollar un modelo fundacional para la clasificación de señales biológicas relacionadas con registros EEG, que aproveche datos no etiquetados en la etapa de autoaprendizaje y datos etiquetados para su ajuste fino.

1. Actividad 1.1: Recopilación y Preprocesamiento de Datos EEG

Se recopilará un conjunto de registros EEG, provenientes de diversas fuentes, y se organizarán tanto bases de datos etiquetadas como no etiquetadas. Se realizará un preprocesamiento inicial que incluya la eliminación de artefactos, la normalización de los datos y la sincronización de las señales para asegurar la homogeneidad en la tasa de muestreo y el número de canales.

2. Actividad 1.2: Desarrollo del Modelo Fundacional

Se diseñará y desarrollará un modelo fundacional empleando técnicas de autoaprendizaje para extraer representaciones generales de las señales EEG. Posteriormente, se aplicará un ajuste fino utilizando los datos etiquetados para optimizar la capacidad del modelo en la clasificación de individuos con trastornos mentales.

3. Actividad 1.3: Validación Interna del Modelo

Se validará el desempeño del modelo fundacional mediante métricas de clasificación. Se ajustarán los hiperparámetros en función de los resultados obtenidos, garantizando la adaptabilidad del modelo a nuevos escenarios clínicos.

Fase 2: Implementación de la Herramienta de Predicción Estocástica Basada en Procesos Gaussianos

Objetivo específico 2: Implementar una herramienta de predicción estocástica basada en procesos Gaussianos, que permita modelar la incertidumbre en la predicción del modelo fundacional.

1. Actividad 2.1: Investigación de Procesos Gaussianos para Modelar Incertidumbre

Realizar una revisión bibliográfica sobre técnicas basadas en procesos Gaussianos en el ámbito de datos biomédicos y EEG, identificando métodos adecuados para cuantificar la incertidumbre en las predicciones.

2. Actividad 2.2: Integración del Componente Gaussianos en el Modelo

Desarrollar e integrar en el modelo fundacional un módulo basado en procesos Gaussianos que estime la incertidumbre asociada a cada predicción, proporcionando una medida cuantitativa de la confiabilidad diagnóstica.

3. Actividad 2.3: Validación de la Herramienta Estocástica

Validar la herramienta de predicción estocástica mediante pruebas en un conjunto de datos inde-

pendiente, evaluando la precisión del modelo y la utilidad de la estimación de incertidumbre para el diagnóstico y tratamiento de trastornos mentales.

Fase 3: Elaboración de Estrategias para el Manejo de la Variabilidad en los Datos

Objetivo específico 3: Diseñar una estrategia para manejar la variabilidad e inconsistencia en conjuntos de datos de registros EEG, permitiendo la integración efectiva de bases de datos con diversos estándares para su aprovechamiento en el modelo.

1. Actividad 3.1: Revisión y Análisis de la Variabilidad en los Datos EEG

Realizar una revisión de la literatura para identificar los principales desafíos asociados a la variabilidad en los conjuntos de datos EEG, tales como valores ausentes, diferencias en la tasa de muestreo, variaciones en el número de canales y el fenómeno de dataset shift.

2. Actividad 3.2: Integración del las técnicas de manejo de variabilidad en los datos al modelo fundacional

Incorporar las estrategias investigadas en la fase anterior al flujo de trabajo del modelo fundacional, de manera que se optimice la capacidad del modelo para manejar señales biológicas.

3. Actividad 3.3: Validación y Documentación de la Estrategia

Validar la efectividad de la estrategia de manejo de variabilidades en los datos mediante pruebas comparativas con datos de EEG, y documentar el proceso que sirva de guía para la implementación y futuras mejoras.

6. Productos de CTe Esperados

- Un informe técnico final.
- Un artículo Q1 sometido en revista indexada.
- Un software registrado.

Referencias

- [1] M. Dehghan-Bonari, M. Alipour-Vaezi, M. M. Nasiri, and A. Aghsami, “A diagnostic analytics model for managing post-disaster symptoms of depression and anxiety among students using a novel data-driven optimization approach,” *Healthcare Analytics*, vol. 4, 12 2023.
- [2] G. Ayano, K. Yohannes, and M. Abraha, “Epidemiology of attention-deficit/hyperactivity disorder (adhd) in children and adolescents in africa: a systematic review and meta-analysis,” *Annals of General Psychiatry*, vol. 19, no. 1, p. 21, Mar 2020. [Online]. Available: <https://doi.org/10.1186/s12991-020-00271-w>
- [3] S. V. Faraone, P. Asherson, T. Banaschewski, J. Biederman, J. K. Buitelaar, J. A. Ramos-Quiroga, L. A. Rohde, E. J. Sonuga-Barke, R. Tannock, and B. Franke, “Attention-deficit/hyperactivity disorder,” *Nature Reviews Disease Primers*, vol. 1, 2015, cited by: 1053. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85010968595&doi=10.1038%2fnrdp.2015.20&partnerID=40&md5=af13ca755f7637047546312aaa659c2b>
- [4] A. Kivumbi, W. Byansi, C. Damulira, P. Namatovu, J. Mugisha, O. Senoy Bahar, M. M. McKay, K. Hoagwood, and F. M. Ssewamala, “Prevalence of behavioral disorders and attention deficit/hyperactive disorder among school going children in southwestern uganda,” *BMC Psychiatry*, vol. 19, no. 1, p. 105, Apr 2019. [Online]. Available: <https://doi.org/10.1186/s12888-019-2069-8>

- [5] R. Zhou, Q. Xia, H. Shen, X. Yang, Y. Zhang, and J. Xu, "Diagnosis of children's attention deficit hyperactivity disorder (ADHD) and its association with cytomegalovirus infection with ADHD: a historical review," *Int J Clin Exp Med*, vol. 8, no. 8, pp. 13 969–13 975, Aug. 2015.
- [6] D. C. Lohani and B. Rana, "Adhd diagnosis using structural brain mri and personal characteristic data with machine learning framework," *Psychiatry Research: Neuroimaging*, vol. 334, p. 111689, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0925492723000999>
- [7] D. Adam, "Mental health: On the spectrum," *Nature*, vol. 496, no. 7446, pp. 416–418, apr 2013. [Online]. Available: <https://doi.org/10.1038/496416a>
- [8] M. H. Sibley, "Empirically-informed guidelines for first-time adult adhd diagnosis," *Journal of Clinical and Experimental Neuropsychology*, vol. 43, no. 4, pp. 340–351, 2021, pMID: 33949916. [Online]. Available: <https://doi.org/10.1080/13803395.2021.1923665>
- [9] P. Asherson, L. Leaver, M. Adamou, M. Arif, G. Askey, M. Butler, S. Cubbin, T. Newlove-Delgado, J. Kustow, J. Lanham-Cook, J. Findlay, J. Maxwell, P. Mason, H. Read, K. van Rensburg, U. Müller-Sedgwick, J. Sedgwick-Müller, and C. Skirrow, "Mainstreaming adult adhd into primary care in the uk: guidance, practice, and best practice recommendations," *BMC Psychiatry*, vol. 22, no. 1, p. 640, Oct 2022. [Online]. Available: <https://doi.org/10.1186/s12888-022-04290-7>
- [10] S. Pallanti and L. Salerno, *The Socioeconomic Burden of Adult ADHD*. Cham: Springer International Publishing, 2020, pp. 1–20. [Online]. Available: https://doi.org/10.1007/978-3-030-39051-8_1
- [11] M. Maniruzzaman, J. Shin, M. A. Hasan, and Y. Akira, "Efficient feature selection and machine learning based adhd detection using eeg signal," *Computers, Materials & Continua*, vol. 72, 04 2022.
- [12] S. K. Khare and U. R. Acharya, "An explainable and interpretable model for attention deficit hyperactivity disorder in children using eeg signals," *Computers in Biology and Medicine*, vol. 155, p. 106676, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0010482523001415>
- [13] H. W. Loh, C. P. Ooi, S. L. Oh, P. D. Barua, Y. R. Tan, U. R. Acharya, and D. S. S. Fung, "Adhd/cd-net: automated eeg-based characterization of adhd and cd using explainable deep neural network technique," *Cognitive Neurodynamics*, vol. 18, no. 4, pp. 1609–1625, Aug 2024. [Online]. Available: <https://doi.org/10.1007/s11571-023-10028-2>
- [14] H. Jahani and A. A. Safaei, "Efficient deep learning approach for diagnosis of attention-deficit/hyperactivity disorder in children based on eeg signals," *Cognitive Computation*, vol. 16, no. 5, pp. 2315–2330, Sep 2024. [Online]. Available: <https://doi.org/10.1007/s12559-024-10302-3>
- [15] M. Garcia-Argibay, Y. Zhang-James, S. Cortese, P. Lichtenstein, H. Larsson, and S. V. Faraone, "Predicting childhood and adolescent attention-deficit/hyperactivity disorder onset: a nationwide deep learning approach," *Molecular Psychiatry*, vol. 28, no. 3, pp. 1232–1239, Mar 2023. [Online]. Available: <https://doi.org/10.1038/s41380-022-01918-8>
- [16] M. Moghaddari, M. Z. Lighvan, and S. Danishvar, "Diagnose adhd disorder in children using convolutional neural network based on continuous mental task eeg," *Computer Methods and Programs in Biomedicine*, vol. 197, 2020, cited by: 100. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85090562418&doi=10.1016%2fcmpb.2020.105738&partnerID=40&md5=c1083c9248e2e050e47a127ec3f19889>
- [17] Z. Emam, A. Kondrich, S. Harrison, F. Lau, Y. Wang, A. Kim, and E. Branson, "On the state of data in computer vision: Human annotations remain indispensable for developing deep learning models," 2021. [Online]. Available: <https://arxiv.org/abs/2108.00114>

- [18] N. K. Iyortsuun, S.-H. Kim, M. Jhon, H.-J. Yang, and S. Pant, “A review of machine learning and deep learning approaches on mental health diagnosis,” *Healthcare*, vol. 11, no. 3, 2023. [Online]. Available: <https://www.mdpi.com/2227-9032/11/3/285>
- [19] G. Mathew, D. Barbosa, J. Prince, and S. Venkatraman, “Foundation models for cardiovascular disease detection via biosignals from digital stethoscopes,” *npj Cardiovascular Health*, vol. 1, p. 25, 10 2024. [Online]. Available: <https://www.nature.com/articles/s44325-024-00027-5>
- [20] S. Abbaspourazad, O. Elachqar, A. C. Miller, S. Emrani, U. Nallasamy, and I. Shapiro, “Large-scale training of foundation models for wearable biosignals,” 12 2023. [Online]. Available: <http://arxiv.org/abs/2312.05409>
- [21] A. Apicella, P. Arpaia, G. D’Errico, D. Marocco, G. Mastrati, N. Moccaldi, and R. Prevete, “Toward cross-subject and cross-session generalization in eeg-based emotion recognition: Systematic review, taxonomy, and methods,” *Neurocomputing*, vol. 604, p. 128354, 2024. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0925231224011251>
- [22] B. Gutierrez Becker, T. Klein, and C. Wachinger, “Gaussian process uncertainty in age estimation as a measure of brain abnormality,” *NeuroImage*, vol. 175, pp. 246–258, 2018. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1053811918302854>
- [23] S. Saxena, M. Funk, and D. Chisholm, “World health assembly adopts comprehensive mental health action plan 2013-2020,” *Lancet*, vol. 381, no. 9882, pp. 1970–1971, Jun. 2013, pMID: 23746771.
- [24] A. Galiana-Simal, P. Vecina-Navarro, P. Sánchez-Ruiz, and M. Vela-Romero, “Electroencefalografía cuantitativa como herramienta para el diagnóstico y seguimiento del paciente con trastorno por déficit de atención/hiperactividad,” *Rev. Neurol.*, vol. 70, no. 06, p. 197, 2020.
- [25] D. A. Pineda, F. Lopera, J. D. Palacio, D. Ramirez, and G. C. Henao, “Prevalence estimations of attention-deficit/hyperactivity disorder: differential diagnoses and comorbidities in a colombian sample,” *International Journal of Neuroscience*, vol. 113, no. 1, pp. 49–71, 2003.
- [26] L. J. Llanos Lizcano *et al.*, “Trastorno por déficit de atención e hiperactividad (tdah) en niños escolarizados de 6 a 17 años,” *Pediatría Aten. Primaria*, vol. 21, no. 83, pp. e101–e108, 2019.
- [27] M. E. Narad *et al.*, “Parent–teacher agreement on adhd symptoms across development,” *Psychological Assessment*, vol. 27, no. 1, p. 239, 2015.
- [28] T. Eslami, F. Almuqhim, J. S. Raiker, and F. Saeed, “Machine learning methods for diagnosing autism spectrum disorder and attention-deficit/hyperactivity disorder using functional and structural mri: A survey,” *Frontiers in Neuroinformatics*, vol. 14, p. 575999, Jan. 2021.
- [29] Y.-L. Yeh, T.-H. Hou, and W.-Y. Chang, “An intelligent model for the classification of children’s occupational therapy problems,” *Expert Systems with Applications*, vol. 39, no. 5, pp. 5233–5242, 2012.
- [30] G. V. Polanczyk, E. G. Willcutt, G. A. Salum, C. Kieling, and L. A. Rohde, “Adhd prevalence estimates across three decades: an updated systematic review and meta-regression analysis,” *International Journal of Epidemiology*, vol. 43, no. 2, pp. 434–442, Apr. 2014.
- [31] M. E. de la Viuda Suárez, J. C. Alonso Lorenzo, F. J. Ruiz Jiménez, and M. C. Luciano Soriano, “Assessing adhd symptoms in clinical public practice: Is a reliable final diagnosis possible?” *Aten. Primaria*, vol. 53, no. 3, p. 101945, Mar. 2021.
- [32] M. R. Arbabshirani, S. Plis, J. Sui, and V. D. Calhoun, “Single subject prediction of brain disorders in neuroimaging: Promises and pitfalls,” *NeuroImage*, vol. 145, p. 137 – 165,

Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-84962787673&doi=10.1016%2fj.neuroimage.2016.02.079&partnerID=40&md5=02c435791465a7d077ad0db2d5ba2137>

- [33] J. D. Pastrana-Cortes, M. C. Maya-Piedrahita, P. M. Herrera-Gómez, D. Cárdenas-Peña, and A. A. Orozco-Gutierrez, "Interpretable diagnosis of adhd based on wavelet features and logistic regression," in *Progress in Artificial Intelligence and Pattern Recognition*, Y. Hernández Heredia, V. Mi-lián Núñez, and J. Ruiz Shulcloper, Eds. Cham: Springer International Publishing, 2021, pp. 424–433.
- [34] C. J. Vaidya, X. You, S. Mostofsky, F. Pereira, M. M. Berl, and L. Kenworthy, "Data-driven identification of subtypes of executive function across typical development, attention deficit hyperactivity disorder, and autism spectrum disorders," *Journal of Child Psychology and Psychiatry and Allied Disciplines*, vol. 61, no. 1, p. 51 – 61, 2020, cited by: 71; All Open Access, Green Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85072172828&doi=10.1111%2fcjcpp.13114&partnerID=40&md5=2c19801a420c8a611573b09d2a121f06>
- [35] H. T. Tor, C. P. Ooi, N. S. Lim-Ashworth, J. K. E. Wei, V. Jahmunah, S. L. Oh, U. R. Acharya, and D. S. S. Fung, "Automated detection of conduct disorder and attention deficit hyperactivity disorder using decomposition and nonlinear techniques with eeg signals," *Computer Methods and Programs in Biomedicine*, vol. 200, 2021, cited by: 93. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85099615028&doi=10.1016%2fj.cmpb.2021.105941&partnerID=40&md5=be182f5ba2f9cd1a27831fe3a7ded6dc>
- [36] E.-A. Paraschiv, M. Ianculescu, and A. Alexandru, "Bridging the gap: Deep learning eeg-based applications for schizophrenia classification and management," vol. 109, 2024, Conference paper, p. 676 – 684, cited by: 0. [Online]. Available: https://www.scopus.com/inward/record.uri?eid=2-s2.0-85210073213&doi=10.1007%2f978-3-031-62502-2_76&partnerID=40&md5=6c97da2b0b743f44999242993d3daed3
- [37] G. Arji, L. Erfannia, S. alirezaei, and M. Hemmat, "A systematic literature review and analysis of deep learning algorithms in mental disorders," *Informatics in Medicine Unlocked*, vol. 40, 2023, cited by: 7; All Open Access, Gold Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85161681016&doi=10.1016%2fj imu.2023.101284&partnerID=40&md5=b1a369fb778fd6fcbb1a2623f0cc92eeb>
- [38] A. Ahmadi, M. Kashefi, H. Shahrokhi, and M. A. Nazari, "Computer aided diagnosis system using deep convolutional neural networks for adhd subtypes," *Biomedical Signal Processing and Control*, vol. 63, p. 102227, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1746809420303578>
- [39] S. Zhang and D. Metaxas, "On the challenges and perspectives of foundation models for medical image analysis," *Medical Image Analysis*, vol. 91, 2024, cited by: 35; All Open Access, Green Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85175172380&doi=10.1016%2fj.media.2023.102996&partnerID=40&md5=9e238dcfdad07138a235e852d56bf7d0>
- [40] D. Wang, X. Wang, L. Wang, M. Li, Q. Da, X. Liu, X. Gao, J. Shen, J. He, T. Shen, Q. Duan, J. Zhao, K. Li, Y. Qiao, and S. Zhang, "A real-world dataset and benchmark for foundation model adaptation in medical image classification," *Scientific Data*, vol. 10, no. 1, 2023, cited by: 10; All Open Access, Gold Open Access, Green Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85169682108&doi=10.1038%2fs41597-023-02460-0&partnerID=40&md5=e491975ddc9a5c14fa6e033a2d878f30>
- [41] S. Abbaspourazad, O. Elachqar, A. C. Miller, S. Emrani, U. Nallasamy, and I. Shapiro, "Large-scale training of foundation models for wearable biosignals," 2024, Conference paper, cited

- by: 2. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85199807514&partnerID=40&md5=151326ca004a05961164e60923cad4a0>
- [42] L. Lim, A. Marquand, A. A. Cubillo, A. B. Smith, K. Chantiluke, A. Simmons, M. Mehta, and K. Rubia, "Disorder-specific predictive classification of adolescents with attention deficit hyperactivity disorder (adhd) relative to autism using structural magnetic resonance imaging," *PLoS ONE*, vol. 8, no. 5, 2013, cited by: 87; All Open Access, Gold Open Access, Green Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-84877826499&doi=10.1371%2fjournal.pone.0063660&partnerID=40&md5=e31429216c7db29697c5c53ddac19103>
- [43] H. Hart, K. Chantiluke, A. I. Cubillo, A. B. Smith, A. Simmons, M. J. Brammer, A. F. Marquand, and K. Rubia, "Pattern classification of response inhibition in adhd: Toward the development of neurobiological markers for adhd," *Human Brain Mapping*, vol. 35, no. 7, p. 3083 – 3094, 2014, cited by: 98; All Open Access, Green Open Access, Hybrid Gold Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-84902213440&doi=10.1002%2fhbm.22386&partnerID=40&md5=d65b9f9465a4be890498a36781cd6bb2>

Artículo Q1

1 Multi-Source Asynchrony Time Series 2 Classification*

3

4 Abstract

5

6 Keywords:

7 1 Introduction

8 Wearable devices enable non-intrusive measurement of physiological biomarkers
9 that correlate with stress levels, emotional states, and other biological responses.
10 Those measurements often include heart rate Variability (HRV), Electrodermal
11 Activity (ADA), Heart Rate (HR), and three-axis acceleration (ACC) [1]. Advances
12 in machine learning have allowed us to predict emotional states from
13 these biomarkers, reflecting a shift toward recognizing mental well-being as an
14 integral component of human health.

15 Authors in [2] evaluate a set of traditional machine learning algorithms to
16 predict people's stress based on EDA activity, including K-Nearest Neighbor,
17 Support Vector Machine (SVM), Naive Bayes, Logistic Regression, and Random
18 Forest. They trained models on both statistical features and raw sensor readings,
19 finding that SVM achieved the highest accuracy, although performance
20 varied inconsistently between feature-based and raw-data approaches.

21 Despite their utility, shallow models often lack expressiveness and capacity to
22 generalize well [3]. Moreover, features often rely on statistics, forgetting sequential
23 dependencies in the data. A closer overview dives us into a multi-modality
24 scenario, where signals are sampled at different frequencies, introducing additional
25 challenges for feature extraction and fusion.

26 Deep learning approaches address these limitations by automatically leveraging
27 data structures as time dependencies for sequential recordings or spatial
28 patterns for images through feature representation from multiple data entities.
29 However, a key challenge lies in effectively combining heterogeneous data sources
30 [4, 5].

31 The work developed by [6] demonstrated the power of multimodal fusion by
32 integrating autoencoders for genetic data with 3D CNNs for imaging, outperforming
33 shallow and single-modality baselines. In the domain of physiological
34 sensing, [7] proposed a CNN-based feature extractor for time-series sensor data,
35 while [8] developed an attention-based LSTM framework to fuse smartphone
36 and wearable signals for emotion recognition. Prior studies by [9, 10] further

*Under grants provided by the research project 111091991908, funded by MINCIENCIAS.

³⁷ highlight the effectiveness of LSTM architectures in modeling inter-participant
³⁸ variability and integrating multiple modalities.

³⁹ 2 Mathematical Framework

⁴⁰ 2.1 Problem Definition

⁴¹ Consider a set of P variables, where the p -th variable contains L_p observations
⁴² as $\mathbf{x} = \{(t_l^{(p)}, x_l^{(p)})\}_{l=1,p=1}^{L_p,P}$, being $x_l^{(p)} \in \mathbb{R}$ the corresponding observation at
⁴³ time $t_l^{(p)} \in \mathbb{R}$. A graph representation of that structure with $P = 3$ is plotted in
⁴⁴ Figure 1. Each \mathbf{x} has its own target variable $\mathbf{y} \in \mathbb{R}^D$, leading to a collection of N
⁴⁵ input-output i.i.d. pairs denoted as $\mathcal{D} = \{\mathbf{x}_n, \mathbf{y}_n\}_{n=1}^N = \{\mathbf{X}, \mathbf{Y}\}$ called training
⁴⁶ set. The task is to generalize the map from each input \mathbf{x} to its corresponding
⁴⁷ target output \mathbf{y} in a stochastic fashion.

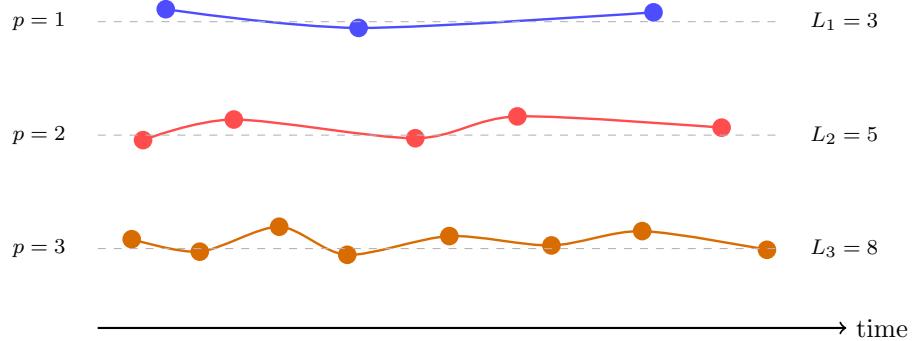


Figure 1: Structure of input samples. Each dot represent a pair $(t_l^{(p)}, x_l^{(p)})$.

⁴⁸ 2.2 Likelihood Model

⁴⁹ For this propose, consider a likelihood functions that rule the generation of
⁵⁰ recorded targets \mathbf{Y} from inputs \mathbf{X} through some set of parameters $\boldsymbol{\theta} \subseteq \mathbb{R}^J$

$$p(\mathbf{Y} | \boldsymbol{\theta}(\mathbf{X})) = \prod_{n=1}^N p(\mathbf{y}_n | \boldsymbol{\theta}(\mathbf{x}_n)). \quad (1)$$

⁵¹ Each element of $\boldsymbol{\theta}(\mathbf{x})$, denoted as $\theta_j(\mathbf{x})$, could be restricted to some subset
⁵² of \mathbb{R} . To handle that, we model $\theta_j(\mathbf{x}) = h_j(f_j(\mathbf{x}))$ as a transformation of an
⁵³ unrestricted latent variable $f_j(\mathbf{x})$ via a link function h_j . Our task boils down
⁵⁴ to finding the latent vector function $\mathbf{f}(\mathbf{x}) = [f_1(\mathbf{x}), \dots, f_J(\mathbf{x})]^\top \in \mathbb{R}^J$.

55 3 Results

56 4 Conclusions

57 References

- 58 [1] G. Vos, K. Trinh, Z. Sarnyai, and M. R. Azghadi, “Generalizable machine
59 learning for stress monitoring from wearable devices: A systematic literature
60 review,” 5 2023.
- 61 [2] L. Zhu, P. Spachos, P. C. Ng, Y. Yu, Y. Wang, K. Plataniotis, and D. Hatzinakos,
62 “Stress detection through wrist-based electrodermal activity monitoring and machine
63 learning,” *IEEE Journal of Biomedical and Health Informatics*, vol. 27, pp. 2155–2165, 5 2023.
- 64 [3] K. Yang, C. Wang, Y. Gu, Z. Sarsenbayeva, B. Tag, T. Dingler, G. Wadley,
65 and J. Goncalves, “Behavioral and physiological signals-based deep multi-
66 modal approach for mobile emotion recognition,” *IEEE Transactions on
67 Affective Computing*, vol. 14, pp. 1082–1097, 4 2023.
- 68 [4] T. Baltrusaitis, C. Ahuja, and L. P. Morency, “Multimodal machine learning:
69 A survey and taxonomy,” 2 2019.
- 70 [5] P. P. Liang, A. Zadeh, and L. P. Morency, “Foundations & trends in multi-
71 modal machine learning: Principles, challenges, and open questions,” *ACM
72 Computing Surveys*, vol. 56, 6 2024.
- 73 [6] J. Venugopalan, L. Tong, H. R. Hassanzadeh, and M. D. Wang, “Multi-
74 modal deep learning models for early detection of alzheimer’s disease
75 stage,” *Scientific Reports*, vol. 11, 12 2021.
- 76 [7] S. Wan, L. Qi, X. Xu, C. Tong, and Z. Gu, “Deep learning models for
77 real-time human activity recognition with smartphones,” *Mobile Networks
78 and Applications*, vol. 25, no. 2, p. 743 – 755, 2020. Cited by: 470.
- 79 [8] K. Yang, C. Wang, Y. Gu, Z. Sarsenbayeva, B. Tag, T. Dingler, G. Wadley,
80 and J. Goncalves, “Behavioral and physiological signals-based deep multi-
81 modal approach for mobile emotion recognition,” *IEEE Transactions on
82 Affective Computing*, vol. 14, no. 2, p. 1082 – 1097, 2023. Cited by: 45.
- 83 [9] G. Zhang and A. Etemad, “Capsule attention for multimodal eeg-eog rep-
84 resentation learning with application to driver vigilance estimation,” *IEEE
85 Transactions on Neural Systems and Rehabilitation Engineering*, vol. 29,
86 p. 1138 – 1149, 2021. Cited by: 65; All Open Access, Gold Open Access,
87 Green Open Access.
- 88 [10] Q. Li, J. Tan, J. Wang, and H. Chen, “A multimodal event-driven lstm
89 model for stock prediction using online news,” *IEEE Transactions on
90 Knowledge and Data Engineering*, vol. 33, no. 10, p. 3323 – 3337, 2021.
91 Cited by: 122; All Open Access, Bronze Open Access.

Referencias

- [Garbarino et al., 2014] Garbarino, M., Lai, M., Bender, D., Picard, R. W., and Tognetti, S. (2014). Empatica e3 – a wearable wireless multi-sensor device for real-time computerized biofeedback and data acquisition. In *Proceedings of the International Conference on Wireless Mobile Communication and Healthcare (ICWMCHM)*, pages 39–42.
- [Svoren et al., 2020] Svoren, H., Thambawita, V., Halvorsen, P., Jakobsen, P., Garcia-Ceja, E., Noori, F. M., Hammer, H. L., Lux, M., Riegler, M. A., and Hicks, S. A. (2020). Toadstool: A dataset for training emotional intelligent machines playing super mario bros. In *Proceedings of the 11th ACM Multimedia Systems Conference, MMSys '20*, page 309–314, New York, NY, USA. Association for Computing Machinery.