

INFORME DE ACTIVIDADES EN EL MARCO DEL PROGRAMA:  
ALIANZA CIENTÍFICA CON ENFOQUE  
COMUNITARIO PARA MITIGAR BRECHAS DE  
ATENCIÓN Y MANEJO DE TRASTORNOS  
MENTALES RELACIONADOS CON IMPULSIVIDAD  
EN COLOMBIA

---

Nombre: Julián David Pastrana Cortés

Contrato de servicios: 5551



**automática**  
Grupo I+D

---

Grupo de investigación en Automática

18 de julio de 2025

# Índice

<b>1. Información general del contrato</b>	<b>3</b>
1.1. Descripción general de la vinculación . . . . .	3
1.2. Objetivo general . . . . .	3
<b>2. State of Art</b>	<b>3</b>
<b>3. Metodología</b>	<b>4</b>
<b>4. Conjunto de Datos</b>	<b>4</b>
4.1. Toadstool: Un conjunto de datos para el entrenamiento de máquinas de inteligencia emocional que juegan a Super Mario Bros . . . . .	4
<b>5. Models</b>	<b>5</b>
5.1. Problem Setting . . . . .	5
5.2. Chained LMC GP . . . . .	5
5.2.1. Likelihood Model . . . . .	5
5.2.2. Linear Model of Coregionalization (LMC) prior . . . . .	5
5.3. Variational Inference . . . . .	6
5.3.1. Inducing variables method . . . . .	6
5.3.2. Latent Posterior . . . . .	7
5.3.3. Predictive distribution . . . . .	7
5.4. Variational Bounds . . . . .	7
5.5. Adam + Natural Gradient Optimization . . . . .	8
5.6. Adaptative Multi-Rate LSTM (AMR LSTM) . . . . .	8
5.6.1. Problem Setting . . . . .	8
<b>6. Resultados</b>	<b>8</b>
<b>7. Anexos</b>	<b>10</b>

## 1. Información general del contrato

<b>Rol</b>	Contratista - Estudiante de Doctorado
<b>Contrato de servicios No.</b>	5551 de 2025
<b>Objeto del contrato</b>	Prestación de servicios profesionales para el Desarrollo de metodología de gamificación para entrenamiento de niños con trastornos de impulsividad ALIANZA CIENTÍFICA CON ENFOQUE COMUNITARIO PARA MITIGAR BRECHAS DE ATENCIÓN Y MANEJO DE TRASTORNOS MENTALES RELACIONADOS CON IMPULSIVIDAD EN COLOMBIA - ACEMATE MINCIENCIAS CONTRATO 790-2023
<b>Período del informe</b>	01 de marzo de 2025 al 31 de marzo de 2025

### 1.1. Descripción general de la vinculación

Como resultado de la vinculación se contribuye al alcance de el objetivo 3 del programa de investigación: ALIANZA CIENTÍFICA CON ENFOQUE COMUNITARIO PARA MITIGAR BRECHAS DE ATENCIÓN Y MANEJO DE TRASTORNOS MENTALES RELACIONADOS CON IMPULSIVIDAD EN COLOMBIA

### 1.2. Objetivo general

Desarrollar una metodología de gamificación para entrenamiento de niños con trastornos de impulsividad ALIANZA CIENTÍFICA CON ENFOQUE COMUNITARIO PARA MITIGAR BRECHAS DE ATENCIÓN Y MANEJO DE TRASTORNOS MENTALES RELACIONADOS CON IMPULSIVIDAD EN COLOMBIA - ACEMATE MINCIENCIAS CONTRATO 790-2023.

## 2. State of Art

Wearable devices enable non-intrusive measurement of physiological biomarkers that correlate with stress levels, emotional states, and other biological responses. Those measurements often include heart rate Variability (HRV), Electrodermal Activity (EDA), Heart Rate (HR), and three-axis acceleration (ACC) [Vos et al., 2023]. Advances in machine learning have allowed us to predict emotional states from these biomarkers, reflecting a shift toward recognizing mental well-being as an integral component of human health.

Authors in [Zhu et al., 2023] evaluate a set of traditional machine learning algorithms to predict people's stress based on EDA activity, including K-Nearest Neighbor, Support Vector Machine (SVM), Naive Bayes, Logistic Regression, and Random Forest. They trained models on both statistical features and raw sensor readings, finding that SVM achieved the highest accuracy, although performance varied inconsistently between feature-based and raw-data approaches.

Despite their utility, shallow models often lack expressiveness and capacity to generalize well [Yang et al., 2023a]. Moreover, features often rely on statistics, forgetting sequential dependencies in the data. A closer overview dives us into a multi-modality scenario, where signals are sampled at different frequencies, introducing additional challenges for feature extraction and fusion.

Deep learning approaches address these limitations by automatically leveraging data structures as time dependencies for sequential recordings or spatial patterns for images through feature representation from multiple data entities. However, a key challenge lies in effectively combining heterogeneous data sources [Baltrusaitis et al., 2019, Liang et al., 2024].

The work developed by [Venugopalan et al., 2021] demonstrated the power of multimodal fusion by integrating autoencoders for genetic data with 3D CNNs for imaging, outperforming shallow and single-modality baselines. In the domain of physiological sensing, [Wan et al., 2020] proposed a CNN-based feature extractor for time-series sensor data, while [Yang et al., 2023b] developed an attention-based LSTM framework to fuse smartphone and wearable signals for emotion recognition. Prior studies by [Zhang and Etemad, 2021, Li et al., 2021] further highlight the effectiveness of LSTM architectures in modeling inter-participant variability and integrating multiple modalities.

Building on these findings, our approach leverages LSTM deep learning models to handle multimodal physiological signals sampled at disparate frequencies. By learning unified temporal representations, LSTMs can capture both short-term fluctuations and long-term trends in the data. Multimodal fusion within this framework enables the model to exploit complementary information across different biomarkers, achieving robustness and accuracy in emotion detection from wearable devices.

### 3. Metodología

Para llevar a cabo el objetivo general planteado, se plantean las siguientes etapas:

- Etapa 1: Revisión del estado del arte sobre gamificación y trastorno de impulsividad para identificar las mejores prácticas y metodologías existentes.
- Etapa 2: Desarrollo de una metodología preliminar de gamificación.
- Etapa 3: Redacción y sometimiento de un artículo de investigación en revista indexada, donde se exponga la metodología preliminar desarrollada.
- Etapa 4: Ampliación de la metodología preliminar de gamificación mediante el uso de Procesos Gaussianos.
- Etapa 5: Redacción y sometimiento de un artículo de investigación en revista indexada, donde se exponga la metodología final desarrollada.
- Etapa 6: Elaboración de un informe técnico final sobre el desarrollo y resultados de las actividades.

### 4. Conjunto de Datos

#### 4.1. Toadstool: Un conjunto de datos para el entrenamiento de máquinas de inteligencia emocional que juegan a Super Mario Bros

El conjunto de datos de libre acceso Toadstool es una colección de registros en video, sensores e información demográfica obtenidos de diez individuos mientras jugaban Super Mario Bros. La selección de los participantes se realizó buscando una amplia variedad en cuanto a experiencia previa con videojuegos, incluyendo desde personas que apenas habían jugado alguno en su vida hasta aquellas con una extensa trayectoria desde la infancia, con edades comprendidas entre los 26 y 48 años. También se buscó mantener un balance en el género, participando cinco hombres y cinco mujeres. Los autores en [Svoren et al., 2020] señalan la presencia de anomalías, tales como ninguna o muy poca actividad detectada por los sensores, así como diferencias significativas entre la actividad registrada al inicio y al final de las sesiones de juego.

El desempeño de los participantes fue evaluado según el número de niveles completados en un tiempo determinado y el número de muertes ocurridas durante la partida. Dicho puntaje se mantuvo en secreto entre los participantes para evitar que se rindieran o relajaran durante el juego. Adicionalmente, se les incentivó mediante una recompensa con el fin de mantener un desempeño competitivo. Un resumen de las características de los participantes se presenta en la Tabla 1.

En el conjunto de datos, se incluye para cada participante un video de su rostro durante la sesión de juego, grabado a una resolución de  $640 \times 480$  píxeles y a 30 fotogramas por segundo. Además, se registran las acciones realizadas mediante el mando de juego para controlar al personaje, así como los datos recopilados por la pulsera Empatica E4. La Empatica E4 es un dispositivo que permite la adquisición en tiempo real de datos fisiológicos, como la actividad electrodérmica (EDA), el pulso de volumen sanguíneo (BVP), la temperatura de la piel y la aceleración en tres ejes [Garbarino et al., 2014].

ID	Edad	Sexo	Mano dominante	Horas por semana	Años de actividad	Experiencia previa	Puntaje del juego
0	26	Hombre	Derecha	4-8	22	Mucha	17,100
1	48	Hombre	Izquierda	0-1	1	Poca	3,000
2	28	Hombre	Derecha	0-1	0	Ninguna	300
3	32	Hombre	Derecha	4-8	4	Algo	13,300
4	32	Mujer	Derecha	0-1	5	Algo	6,400
5	30	Mujer	Derecha	0-1	5	Poca	2,700
6	35	Hombre	Izquierda	1-4	30	Mucha	14,300
7	34	Mujer	Derecha	1-4	14	Algo	3,800
8	31	Mujer	Derecha	0-1	2	Poca	200
9	27	Mujer	Derecha	0-1	5	Poca	10,600

Tabla 1: Características demográficas y experiencia de los participantes en relación con su desempeño en el juego. Se incluyen datos como edad, sexo, lateralidad, dedicación semanal, años de experiencia, nivel de experiencia previa y puntaje obtenido.

## 5. Models

### 5.1. Problem Setting

Consider a time-series vector collecting sequential data observed across  $P$  output at some time instant  $t$ , denoted as  $\mathbf{v}_t \subseteq \mathbb{R}^P$ . We want to include  $T \in \mathbb{Z}^{++}$  sequential observations simultaneously back as a vector  $\mathbf{x}$  belonging to some input space  $\mathcal{X}$ , that is

$$\mathbf{x} = [\mathbf{v}_{t-1}^\top, \mathbf{v}_{t-2}^\top, \dots, \mathbf{v}_{t-T}^\top]^\top,$$

and therefore  $\mathcal{X} \subseteq \mathbb{R}^L$ , with  $L = PT$ , and  $T$  is model order. We are interesting to predict next  $H \in \mathbb{Z}^{++}$  sequential values, giving the output target  $\mathbf{y} \in \mathcal{Y}$  as

$$\mathbf{y} = [\mathbf{v}_t^\top, \mathbf{v}_{t+1}^\top, \dots, \mathbf{v}_{t+H-1}^\top]^\top,$$

thus, the output space  $\mathcal{Y} \subseteq \mathbb{R}^D$ , with  $D = PH$ , and  $H$  is model Horizon. The above formulation enables the model to leverage sequential data for accurate future predictions. We build a train dataset compound by  $N$  input-output i.i.d. pair observations as  $\mathcal{D} = \{\mathbf{x}_n, \mathbf{y}_n\}_{n=1}^N = \{\mathbf{X}, \mathbf{Y}\}$ .

### 5.2. Chained LMC GP

#### 5.2.1. Likelihood Model

We start by setting the likelihood function assuming the distribution over  $\mathbf{y}_n$  as the product of  $D$  conditionally independent distributions, one by output as follows:

$$p(\mathbf{Y} \mid \boldsymbol{\theta}(\mathbf{X})) = \prod_{n=1}^N p(\mathbf{y}_n \mid \boldsymbol{\theta}(\mathbf{x}_n)) = \prod_{n=1}^N \prod_{d=1}^D p(y_{d,n} \mid \boldsymbol{\theta}_d(\mathbf{x}_n)), \quad (1)$$

begin  $\boldsymbol{\theta}(\mathbf{X}) = \{\boldsymbol{\theta}_d(\mathbf{x}_n)\}_{n=1, d=1}^{N, D}$ , with  $\boldsymbol{\theta}_d(\mathbf{x}) \subseteq \mathbb{R}^{J_d}$  as a vector containing  $J_d$  parameter for  $d$ -th output distribution. Each element of  $\boldsymbol{\theta}_d(\mathbf{x})$ , denoted as  $\theta_{d,j}(\mathbf{x})$ , could be restricted to some subset of  $\mathbb{R}$ . To handle that, we model  $\theta_{d,j}(\mathbf{x}) = h_{d,j}(f_{d,j}(\mathbf{x}))$  as a transformation of an unrestricted latent variable  $f_{d,j}(\mathbf{x})$  via a link function  $h_{d,j}$ .

#### 5.2.2. Linear Model of Coregionalization (LMC) prior

Our main task is reduced to model each  $f_{d,j}$  and plug-in it in Equation (1). Consider a set of  $Q$  independent GPs  $\{g_q\}_{q=1}^Q$  over the input space such that  $g_q(\mathbf{x}) \sim \mathcal{GP}(0, k_q(\mathbf{x}, \mathbf{x}'))$  with kernel parameters  $\Phi_q$  that will be linearly weighed via  $a_{(d,j),q} \in \mathbb{R}$  coefficients to generate  $f_{d,j}$  by:

$$f_{d,j}(\mathbf{x}) = \sum_{q=1}^Q a_{(d,j),q} g_q(\mathbf{x}). \quad (2)$$

With that in mind, the cross-covariance function of the latent variable  $f_{d,j}$  is as follows:

$$\begin{aligned} k_{f_{d,j}, f_{d',j'}}(\mathbf{x}, \mathbf{x}') &= \text{cov}\{f_{d,j}(\mathbf{x}), f_{d',j'}(\mathbf{x}')\} \\ &= \sum_{q=1}^Q \sum_{q'=1}^Q a_{(d,j),q} a_{(d',j'),q'} \text{cov}\{u_q(\mathbf{x}), u_{q'}(\mathbf{x}')\} \\ &= \sum_{q=1}^Q a_{(d,j),q} a_{(d',j'),q} k_q(\mathbf{x}, \mathbf{x}'). \end{aligned} \quad (3)$$

In this way, output dependencies are shared via the mixing process described in Equation (3), allowing each  $f_{d,j}$  to be composed as a set of features granted by  $g_q$  through by coefficients  $a_{(d,j),q}$ .

### 5.3. Variational Inference

So far, the LMC model does not take into account data observation set  $\mathcal{D}$  and only relies on prior knowledge. Let us group all latent variables located at all train points  $f_{d,j}(\mathbf{x}_n)$  into a vector  $\mathbf{f} \in \mathbb{R}^{NJ}$  where  $J = \sum_{d=1}^D J_d$ , and the likelihood function in Equation (1) can be notated as  $p(\mathbf{Y} | \mathbf{f})$ . According to Equation (2),  $\mathbf{f} \sim \mathcal{N}(\mathbf{0}, \mathbf{K}_{\mathbf{f},\mathbf{f}})$ , and  $\mathbf{K}_{\mathbf{f},\mathbf{f}} \in \mathbb{R}^{NJ \times NJ}$  is filled out by the kernel function in Equation (3) evaluated at each pair of elements in  $\mathbf{X}$ . The posterior distribution  $p(\mathbf{f} | \mathbf{Y}) = p(\mathbf{Y} | \mathbf{f})p(\mathbf{f})/p(\mathbf{Y})$  can be intractable whether due to non-Gaussian likelihood assumption and do not achieve a close form or do it and bear a high complexity of  $\mathcal{O}(N^3 J^3)$ .

#### 5.3.1. Inducing variables method

The main idea behind inducing variables method is to generate a new vector  $\mathbf{u} \in \mathbb{R}^{MQ}$  with elements  $g_q(\mathbf{z}_m)$  corresponding the  $Q$  independent processes evaluated at  $M \ll N$  inducing points denoted as  $\mathbf{Z} = \{\mathbf{z}_m\}_{m=1}^M$  such as  $\mathbf{z}_m \in \mathcal{X}$ . Inasmuch as consistence of GP,  $\mathbf{u} \sim \mathcal{N}(\mathbf{0}, \mathbf{K}_{\mathbf{u},\mathbf{u}})$ , and  $\mathbf{K}_{\mathbf{u},\mathbf{u}} \in \mathbb{R}^{MQ \times MQ}$ . Now we focus on the joint Gaussian prior  $p(\mathbf{f}, \mathbf{u}) = p(\mathbf{f} | \mathbf{u})p(\mathbf{u})$ . Due to independence property of  $\mathbf{u}$  process,  $p(\mathbf{u}) = \prod_{q=1}^Q p(\mathbf{u}_q) = \prod_{q=1}^Q \mathcal{N}(\mathbf{u}_q | \mathbf{0}, \mathbf{K}_{\mathbf{u}_q, \mathbf{u}_q})$ ,

$$\begin{aligned} p(\mathbf{f} | \mathbf{u}) &= \prod_{d=1}^D \prod_{j=1}^{J_d} p(\mathbf{f}_{d,j} | \mathbf{u}) \\ &= \prod_{d=1}^D \prod_{j=1}^{J_d} \mathcal{N}(\mathbf{f}_{d,j} | \mathbf{K}_{\mathbf{u}, \mathbf{f}_{d,j}}^\top \mathbf{K}_{\mathbf{u}, \mathbf{u}}^{-1} \mathbf{u}, \mathbf{K}_{\mathbf{f}_{d,j}, \mathbf{f}_{d,j}} - \mathbf{K}_{\mathbf{u}, \mathbf{f}_{d,j}}^\top \mathbf{K}_{\mathbf{u}, \mathbf{u}}^{-1} \mathbf{K}_{\mathbf{u}, \mathbf{f}_{d,j}}), \end{aligned} \quad (4)$$

and notation is as follows:  $\mathbf{u}_q = [g_q(\mathbf{z}_1), \dots, g_q(\mathbf{z}_M)]^\top \in \mathbb{R}^M$  is a random vector, with covariance matrix  $\mathbf{K}_{\mathbf{u}_q, \mathbf{u}_q} \in \mathbb{R}^{M \times M}$  filled out by the  $q$ -th kernel function of the independent process  $k_q$  evaluate at each pair of elements in  $\mathbf{Z}$ . Similarly,  $\mathbf{f}_{d,j} = [f_{d,j}(\mathbf{x}_1), \dots, f_{d,j}(\mathbf{x}_N)]^\top \in \mathbb{R}^N$  is a zero-mean random vector, with covariance matrix  $\mathbf{K}_{\mathbf{f}_{d,j}, \mathbf{f}_{d,j}} \in \mathbb{R}^{N \times N}$  with elements given by kernel function in Equation (3) evaluate at each pair of points in  $\mathbf{X}$  that is also Gaussian.

Our focus is placed on approximate the joint posterior distribution  $p(\mathbf{f}, \mathbf{u} | \mathcal{D})$  as follows:

$$p(\mathbf{f}, \mathbf{u} | \mathcal{D}) \approx q(\mathbf{f}, \mathbf{u}) = p(\mathbf{f} | \mathbf{u})q(\mathbf{u}) = \prod_{d=1}^D \prod_{j=1}^{J_d} p(\mathbf{f}_{d,j} | \mathbf{u}) \prod_{q=1}^Q q(\mathbf{u}_q), \quad (5)$$

where  $q$  distribution refers to a posterior approximation. Provided the above,  $q(\mathbf{u}) = \mathcal{N}(\mathbf{u} | \boldsymbol{\mu}, \mathbf{S})$  and  $q(\mathbf{u}_q) = \mathcal{N}(\mathbf{u}_q | \boldsymbol{\mu}_q, \mathbf{S}_q)$  are called variational distributions assumed Gaussian-shaped. Also,  $\boldsymbol{\mu} = [\boldsymbol{\mu}_1^\top, \boldsymbol{\mu}_2^\top, \dots, \boldsymbol{\mu}_Q^\top]^\top \in \mathbb{R}^{MQ}$ , and  $\mathbf{S} \in \mathbb{R}^{MQ \times MQ}$  is a block-diagonal matrix with blocks given by  $\mathbf{S}_q \in \mathbb{R}^{M \times M}$ .

### 5.3.2. Latent Posterior

The approximate marginal posterior for  $\mathbf{f}_{d,j}$  denoted  $q(\mathbf{f}_{d,j}) = \int p(\mathbf{f}_{d,j} | \mathbf{u})q(\mathbf{u})d\mathbf{u}$  has a close form giving by

$$q(\mathbf{f}_{d,j}) = \mathcal{N}\left(\mathbf{f}_{d,j} | \mathbf{K}_{\mathbf{u},\mathbf{f}_{d,j}}^\top \mathbf{K}_{\mathbf{u},\mathbf{u}}^{-1} \boldsymbol{\mu}, \mathbf{K}_{\mathbf{f}_{d,j},\mathbf{f}_{d,j}} - \mathbf{K}_{\mathbf{u},\mathbf{f}_{d,j}}^\top \mathbf{K}_{\mathbf{u},\mathbf{u}}^{-1} (\mathbf{S} - \mathbf{K}_{\mathbf{u},\mathbf{u}}) \mathbf{K}_{\mathbf{u},\mathbf{u}}^{-1} \mathbf{K}_{\mathbf{u},\mathbf{f}_{d,j}}\right). \quad (6)$$

The complexity of this model is now  $\mathcal{O}(JNQM^2)$ .

### 5.3.3. Predictive distribution

Consider a test point  $\mathbf{x}_* \in \mathcal{X}$ . Assuming a good approximation of the variational posterior  $p(\mathbf{u} | \mathbf{y}) \approx q(\mathbf{u})$ , the posterior of latent parameter function vector at test point  $\mathbf{f}_* \in \mathbb{R}^J$  takes the form

$$q(\mathbf{f}_*) = \int p(\mathbf{f}_* | \mathbf{u})q(\mathbf{u})d\mathbf{u}, \quad (7)$$

which is filled out similarty to Equation (6). The predictive distribution at the test input  $\mathbf{y}_* \in \mathcal{Y}$ , given the observed data  $\mathcal{D}$ , can thus be approximated as:

$$p(\mathbf{y}_* | \mathcal{D}) \approx \int p(\mathbf{y}_* | \mathbf{f}_*)q(\mathbf{f}_*)d\mathbf{f}_*, \quad (8)$$

which integrates over the latent function vector  $\mathbf{f}_*$  to account for its uncertainty in the prediction of  $\mathbf{y}_*$ . Compute Equation (8) could be intractable. However, statistics like mean and variance can be approximated via Monte Carlo methods.

## 5.4. Variational Bounds

The learnable parameters in our model encompass the variational parameters  $\boldsymbol{\mu}_q$  and  $\mathbf{S}_q$ , inducing points  $\mathbf{Z}$ , and kernel parameters  $a_{(d,j),q}$  and  $\Phi_q$ . To select it optimally, we use the lower bound  $\mathcal{L}$  for  $\log p(\mathbf{y})$  loss function, obtained as follows:

$$\begin{aligned} \log p(\mathbf{y}) &= \log \iint p(\mathbf{y} | \mathbf{f}) p(\mathbf{f} | \mathbf{u}) p(\mathbf{u}) d\mathbf{f} d\mathbf{u} \\ &\geq \iint q(\mathbf{f}, \mathbf{u}) \log \frac{p(\mathbf{y} | \mathbf{f}) p(\mathbf{f} | \mathbf{u}) p(\mathbf{u})}{q(\mathbf{f}, \mathbf{u})} d\mathbf{f} d\mathbf{u} = \mathcal{L}. \end{aligned} \quad (9)$$

We can further simplify  $\mathcal{L}$  to get

$$\begin{aligned} \mathcal{L} &= \iint q(\mathbf{f}, \mathbf{u}) \log \frac{p(\mathbf{y} | \mathbf{f}) p(\mathbf{f} | \mathbf{u}) p(\mathbf{u})}{q(\mathbf{f}, \mathbf{u})} d\mathbf{f} d\mathbf{u} \\ &= \iint q(\mathbf{f}, \mathbf{u}) \log p(\mathbf{y} | \mathbf{f}) d\mathbf{f} d\mathbf{u} - \int q(\mathbf{u}) \log \frac{q(\mathbf{u})}{p(\mathbf{u})} d\mathbf{u} \\ &= \int q(\mathbf{f}) \log p(\mathbf{y} | \mathbf{f}) d\mathbf{f} - \sum_{q=1}^Q \text{KL}\{q(\mathbf{u}_q) \| p(\mathbf{u}_q)\} \\ &= \mathbb{E}_{q(\mathbf{f})} \{\log p(\mathbf{y} | \mathbf{f})\} - \sum_{q=1}^Q \text{KL}\{q(\mathbf{u}_q) \| p(\mathbf{u}_q)\} \\ &= \sum_{d=1}^D \mathbb{E}_{q(\mathbf{f}_{d,1}), \dots, q(\mathbf{f}_{d,J_d})} \{\log p(\mathbf{y}_d | \mathbf{f}_{d,1}, \dots, \mathbf{f}_{d,J_d})\} - \sum_{q=1}^Q \text{KL}\{q(\mathbf{u}_q) \| p(\mathbf{u}_q)\} \\ &= \sum_{n=1}^N \sum_{d=1}^D \mathbb{E}_{q(\mathbf{f}_{d,1,n}), \dots, q(\mathbf{f}_{d,J_d,n})} \{\log p(\mathbf{y}_{d,n} | \mathbf{f}_{d,1,n}, \dots, \mathbf{f}_{d,J_d,n})\} - \sum_{q=1}^Q \text{KL}\{q(\mathbf{u}_q) \| p(\mathbf{u}_q)\}, \end{aligned} \quad (10)$$

being  $\text{KL}\{q(\mathbf{u}_q) \parallel p(\mathbf{u}_q)\}$  the Kullback-Leibler divergence between two Gaussian distributions, with a closed form solution, working as a regularization factor.

### 5.5. Adam + Natural Gradient Optimization

The optimization step for the Chained LMC GP involves several key parameters: kernel parameters (such as characteristic lengthscales and output scale for the exponential quadratic kernel), the set of inducing point locations, and the variational distribution parameters. According to [Giraldo and Alvarez, 2021], there is a strong dependency between the variational parameters and the others, making the model extremely sensitive to any changes in these variables. Additionally, since the ELBO loss function is generally non-convex, stochastic gradient optimization methods often converge to poor local minima.

Recent research has found a beneficial use of Natural Gradient (NG) optimization to overcome the issue mentioned above. The work developed by [Salimbeni et al., 2018] demonstrates the advantages of NG for variational GPs optimization with minimal effort and how to combine it with the Adam optimizer, providing a hybrid optimization framework. In the same spirit, we propose an optimization scheme where the variational parameters are governed by Natural Gradient (NG) optimization, while the others are optimized using the Adam optimizer and we refer to this Adam + NG. That approach allows us to achieve a similar optimization performance as Adam's as if we were optimizing an exact model.

### 5.6. Adaptive Multi-Rate LSTM (AMR LSTM)

#### 5.6.1. Problem Setting

Consider a train dataset, comprising  $N$  input-output pairs of examples denoted as  $\mathcal{D} = \{(\mathbf{X}i, yi)\}_{i=1}^N$ , where  $\mathbf{X}i \in \mathcal{X}$  and  $yi \in \mathcal{Y}$  belongs to some input and output space respectively. Here  $\mathcal{X}$  is the space of collections of, at most,  $P$  vector sequences data observed within a fixed window of  $T$  fundamental time steps:

$$\mathbf{X}i = \{\mathbf{x}i^{(1)}, \dots, \mathbf{x}i^{(t)}, \dots, \mathbf{x}i^{(T)}\}.$$

At each time step  $t \in \{1, \dots, T\}$ , the observed vector is

$$\mathbf{x}i^{(t)} \in \mathbb{R}^{P_t}, P_t \in \{1, \dots, P\}.$$

The dimensionality  $P_t$  at each time step varies depending on which signals are present at that particular instant due to their individual sampling rates, as shown in Figure 1.




Figura 1: Structure of input space

## 6. Resultados

Se presenta la versión definitiva de la propuesta de doctorado sobre modelos funcionales y procesos Gaussianos aplicados a la detección y tratamiento de trastornos mentales, documentada en la sección de anexos.



Simultáneamente, se ha implementado en Python un modelo de inferencia basado en procesos Gaussianos encadenados para ampliar la metodología de gamificación, El desempeño de este enfoque se ha puesto a prueba mediante la exploración y revisión de la base de datos Toadstool. Lo anterior ha dado pie para el avance en la redacción de un artículo científico para su sometimiento a una revista indexada.

Se ha desarrollado un modelo basado en redes neuronales recurrentes LSTM que permite la integración simultánea de múltiples series de tiempo tomadas con diferentes frecuencias de muestreo, dando paso a una primera integración multimodal. Además, se construyó una rutina que permite la carga eficiente de los datos y el manejo de clases desbalanceadas correspondiente al Toadstool dataset para el correcto entrenamiento de este modelo. Lo anterior ha dado inicio al desarrollo matemático de dicho modelo y por lo tanto un avance en la redacción de un artículo científico.

## 7. Anexos

Propuesta doctorado

# **Integración de Modelos Fundacionales y Procesos Gaussianos para el Apoyo al Diagnóstico y Tratamiento de Trastornos Mentales a partir de Señales Electroencefalográficas .**

Julián David Pastrana Cortés, M.Sc.

## **Resumen**

El diagnóstico de trastornos mentales y algunas terapias tradicionalmente se basan en evaluaciones clínicas, entrevistas y pruebas estandarizadas, lo cual puede conllevar interpretaciones subjetivas y requerir un seguimiento prolongado. Además, la generación de modelos de inteligencia artificial que apoyen la práctica clínica suele depender de grandes volúmenes de datos etiquetados, restringe su transferencia a ambientes reales. En este contexto, el presente proyecto propone el desarrollo de un modelo fundacional estocástico basado en procesos Gaussianos para el entrenamiento de modelos de Inteligencia Artificial (IA) a partir de múltiples bases de datos de señales electroencefalográficas (EEG) con características de adquisición variantes, que integre datos no etiquetados mediante técnicas de autoaprendizaje y datos etiquetados para su ajuste fino. Este enfoque no solo busca extraer representaciones generales a partir de la estructura de las señales biológicas, sino que también incorpora un componente que modela la incertidumbre en las predicciones, ofreciendo una medida cuantitativa de la confiabilidad del modelo. Se espera que los resultados impulsen la generación de nuevo conocimiento y la innovación en los ámbitos de la salud, la ingeniería y la ciencia.

## **Abstract**

The diagnosis of mental disorders and certain therapies have traditionally relied on clinical evaluations, interviews, and standardized tests, which can lead to subjective interpretations and require prolonged follow-up. Moreover, the development of artificial intelligence models that support clinical practice typically depends on large volumes of labeled data, limiting their transfer to real-world settings. In this context, the present project proposes the development of a stochastic foundational model based on Gaussian processes for training AI models using multiple databases of electroencephalographic (EEG) signals with varying acquisition characteristics. This model integrates unlabeled data through self-learning techniques and labeled data for fine-tuning. This approach not only seeks to extract general representations from the structure of biological signals but also incorporates a component that models prediction uncertainty, providing a quantitative measure of the model's reliability. It is expected that the results will spur the generation of new knowledge and innovation in the fields of health, engineering, and science.

## **1. Planteamiento del problema y pregunta de investigación**

Los trastornos mentales afectan la cognición, el comportamiento y las emociones de millones de personas en el mundo. Se estima que alrededor de 350 millones de individuos padecen algún trastorno mental [1]. La impulsividad, como característica sintomática central, está presente en diversas condiciones mentales, entre las que destacan el Trastorno Negativista Desafiante (TND), el Trastorno de Desregulación del Estado de Ánimo Disruptivo (TDEAD) y el Trastorno Bipolar (TB). Dentro de este grupo, el Trastorno por Déficit de Atención e Hiperactividad (TDAH) representa un desafío clínico significativo, con una prevalencia aproximada del 5 % en población infantil y adolescente, y del 2.5 % en adultos, constituyendo así uno de los trastornos neuropsiquiátricos más comunes durante la infancia y la adolescencia.

Estos trastornos no solo dificultan el rendimiento académico y laboral [2], sino que también aumenta el riesgo de presentar otros problemas psiquiátricos, conductas delictivas y adicciones [3].

La detección e intervención temprana de la impulsividad es esencial para brindar un tratamiento oportuno y efectivo [4]. Sin embargo, las técnicas diagnósticas actuales presentan limitaciones importantes: muchas pruebas requieren un seguimiento prolongado [5], pueden estar sujetas a interpretaciones subjetivas [6], omitirse debido a la gran variación en las presentaciones clínicas y síntomas [7], y muchos criterios resultan ineficientes para el diagnóstico en adultos [8]. Además, el acceso a un tratamiento clínico y seguimiento es frecuentemente restringido debido a la falta de recursos o la escasez de especialistas [9, 10].

El avance en el desarrollo de modelos de aprendizaje automático ha permitido la creación de herramientas que apoyan el diagnóstico y tratamiento de diversas enfermedades neurológicas y trastornos mentales [11]. Generalmente, estos modelos utilizan señales electroencefalográficas (EEG) para clasificar registros según la presencia o ausencia de la enfermedad, mediante un enfoque de clasificación binaria. No obstante, la naturaleza no estacionaria y la complejidad inherente a las señales EEG complican su análisis utilizando modelos tradicionales [12, 13].

El uso de técnicas de aprendizaje profundo se presenta como una alternativa prometedora, ya que permite extraer características abstractas de las señales EEG mediante una gran cantidad de parámetros [14, 15, 16]. No obstante, el entrenamiento de estos modelos demanda grandes volúmenes de datos etiquetados en un entorno supervisado, lo cual frecuentemente es costoso o inviable, y su potencial mejora se ve limitada por la falta de interpretabilidad [17, 18].

Para superar esta limitación, han surgido los modelos fundacionales, que permiten preentrenar con conjuntos de datos no etiquetados y, posteriormente, ajustar el modelo para tareas específicas utilizando una cantidad significativamente menor de datos etiquetados [19, 20]. Este enfoque aprovecha la estructura subyacente presente en datos sin clasificar, permitiendo que el modelo aprenda representaciones generales robustas. Gracias a este preentrenamiento, el modelo puede transferir conocimientos a tareas concretas, lo que reduce la dependencia de grandes volúmenes de datos anotados y agiliza el proceso de adaptación a nuevos escenarios.

Un aspecto relevante en el preentrenamiento de estos modelos es la variabilidad inherente a los conjuntos de datos no etiquetados. Estas bases de datos pueden diferir en los estándares de adquisición, lo que se manifiesta en la presencia de valores ausentes, variaciones en la tasa de muestreo, diferencias en el número de canales e incluso problemas de generalización al cambiar de sujetos o sesiones (conocido como Dataset Shift) [21]. Descartar estos datos supondría la pérdida de información potencialmente valiosa; por ello, es importante desarrollar un modelo fundacional capaz de gestionar eficazmente dichas inconsistencias y maximizar el aprovechamiento de los datos disponibles.

Lo anterior también induce una incertidumbre en el modelo, por lo que en el ámbito clínico no es suficiente obtener una predicción puntual en el diagnóstico, sino también disponer de una medida de la incertidumbre asociada que cuantifique el nivel de riesgo a la hora de tomar una decisión basada en la inferencia del modelo. En este sentido, los procesos Gaussianos ofrecen una solución al generar una distribución de probabilidad predictiva mediante un enfoque Bayesiano en lugar de una predicción puntual [22, 14]. Sin embargo, la integración de procesos Gaussianos con modelos fundacionales aún es un área poco explorada y con un gran potencial de mejora.

**Pregunta de investigación:** ¿Cómo desarrollar un modelo fundacional estocástico para la inferencia a partir de señales biológicas que integre procesos Gaussianos, para el soporte a la práctica clínica mediante el análisis de señales EEG, considerando la variabilidad e inconsistencias presentes en los conjuntos de datos?

## 2. Justificación

Desde el ámbito de la salud pública, los trastornos mentales son considerados una prioridad mundial debido a sus implicaciones en el desarrollo social. Su presencia está asociada con el fracaso escolar, comportamientos antisociales e incluso delincuencia. Estos presentan subtipos según su gravedad: leve, moderado o grave. Su etiología está relacionada con factores genéticos, neurobiológicos, prenatales, perinatales y posnatales, cuya interacción contribuye a su manifestación clínica [23].

El Plan Nacional de Desarrollo 2022-2026 (PND), Colombia Potencia Mundial de la Vida, busca trabajar mediante un enfoque preventivo y predictivo, estrategias orientadas a promover la capacidad de agencia y cuidado de la salud. En su sección, Salud y bienestar para las juventudes, propone fomentar el bienestar mental, con el objetivo de abordar las causas que inciden en la salud mental de los jóvenes y fomentar las prácticas profesionales que potencien su acompañamiento.

Por su parte, el CONPES 3992 establece estrategias para la promoción de la salud mental, incluyendo la investigación y la integración de sistemas de información en el área. En particular, el Departamento Nacional de Planeación (DNP) desarrolla un modelo predictor de determinantes sociales incidentes en la salud mental para orientar políticas de promoción. Asimismo, el Ministerio de Salud y Protección Social promueve estrategias para la atención en salud e inclusión social.

Solamente la prevalencia mundial del TDAH oscila entre el 5 % y 10 % en niños en edad escolar [24], en Colombia se han reportado valores del 15-17 %, ubicándose entre las cifras más altas de Latinoamérica [25]. Se estima que la prevalencia por rango de edad es del 62 % en niños entre 6 y 11 años, debido a alteraciones en la maduración cerebral, lo que se traduce en un retraso de entre 2 y 3 años con respecto a niños sin la condición [26].

El diagnóstico de los trastornos mentales se basa en los criterios del DSM-5, a partir de información aportada por el paciente o su entorno sobre síntomas percibidos de inatención, impulsividad e hiperactividad, los cuales deben mantenerse durante al menos seis meses, no ser acordes al nivel de desarrollo y afectar el desempeño social, académico o laboral. Sin embargo, la ponderación subjetiva de los síntomas conlleva restricciones como discrepancias en las percepciones entre padres, maestros y profesionales [27], la variabilidad e inconsistencia en la adopción de guías clínicas y criterios insuficientes del DSM-5 [28, 29]. Además, la cobertura diagnóstica es limitada: solo el 7.4 % de los casos recibe confirmación mediante entrevista psiquiátrica estructurada, y solo el 6.6 % recibe tratamiento [30], lo que genera una alta tasa de diagnósticos erróneos en la población infantil de la región [31].

Paralelamente, se han desarrollado plataformas digitales e interfaces avanzadas para la interacción con pacientes, las cuales pueden facilitar el diagnóstico y tratamiento de diversas patologías. Entre estas, los videojuegos han cobrado relevancia como herramientas asistenciales, debido a su capacidad para mejorar la flexibilidad cognitiva y la memoria de trabajo, aspectos clave en la atención y concentración. La Política Nacional de Ciencia, Tecnología e Innovación 2021–2030 fomenta el desarrollo de tecnologías innovadoras en este ámbito. En este contexto, el grupo de investigación en Automática ha desarrollado un amplio trabajo en áreas relacionadas con el análisis de señales biológicas, el modelado de procesos estocásticos y el aprendizaje automático, con aplicaciones en el ámbito de la salud y los trastornos mentales. Además, cuenta con equipos clínicos especializados para la adquisición y análisis de registros EEG.

En conclusión, es necesario fortalecer los programas de salud mental infantil para detectar a tiempo los factores asociados a los trastornos mentales y mejorar los indicadores de prevalencia. Además, resulta importante optimizar la calidad en el diagnóstico, evaluación e intervención de los pacientes. En este sentido, esta propuesta se enfoca en enfrentar estos desafíos, reconociendo que se trata de un problema de salud pública de gran magnitud, mediante el desarrollo de una herramienta de apoyo para el diagnóstico y tratamiento de trastornos mentales a partir de señales EEG, que no solo contribuya a generar nuevos conocimientos, sino que también impulse la innovación en los sectores de la salud, la ingeniería y la

ciencia.

### 3. Estado del arte

Diversos modelos de aprendizaje automático han sido propuestos para apoyar el diagnóstico de trastornos mentales, como la esquizofrenia, alzheimer, depresión y autismo [32]. Por ejemplo, en [33] se implementó un modelo basado en un regresor logístico que utiliza la transformada wavelet para la clasificación de registros electroencefalográficos, permitiendo resaltar características relevantes. Asimismo, en [34] se utilizaron máquinas de soporte vectorial, las cuales ofrecen resultados interpretables para orientar las decisiones clínicas. Además, en [35] se presentó un sistema automatizado de clasificación para diferenciar entre diferentes trastornos mentales, utilizando técnicas de descomposición para extraer características discriminatorias.

Por otro lado, en [36] se implementaron modelos de aprendizaje profundo, combinando capas convolucionales y de memoria LSTM, evidenciando su potencial en la evaluación de la esquizofrenia. Además, en [37] se empleó una arquitectura basada en redes neuronales convolucionales, revelando su utilidad en análisis en la depresión y el estado de ánimo. Por último, en [38] se propone una red convolucional profunda para extraer características discriminatorias y distinguir entre dos subtipos de trastornos mentales, logrando una precisión cercana al 99.46%.

Por su parte, los modelos fundacionales emergen como herramientas de inteligencia artificial preentrenadas a gran escala, capaces de adaptarse a tareas específicas y, en consecuencia, de posibilitar diagnósticos personalizados en el ámbito clínico. En [39] se ilustra un amplio espectro de modelos fundacionales aplicados a la medicina, evidenciando su potencial en aplicaciones de salud basadas en imágenes. Asimismo, en [40] se proponen estos modelos para la clasificación de imágenes provenientes de múltiples fuentes, logrando un rendimiento aceptable y eficiencia en términos de costo para aplicaciones clínicas. Además, en [41] se demuestra que el empleo de aprendizaje auto-supervisado aplicado a grandes volúmenes de datos de fotopletimografía y electrocardiograma permite entrenar modelos fundacionales capaces de extraer información relevante sobre el estado de salud de los usuarios, lo que facilita la detección temprana de la enfermedad y el seguimiento de sus comorbilidades.

Los procesos Gaussianos han sido ampliamente utilizados en diversos estudios para mejorar la precisión en el diagnóstico y la comprensión de los trastornos mentales, aprovechando sus propiedades no paramétricas y estocásticas. Por ejemplo, en [42] se implementó un clasificador basado en este modelo, el cual empleó datos relativos al volumen de la materia gris para discriminar entre individuos sanos, alcanzando una precisión cercana al 79.3%. De manera similar, en [43] se aplicó un clasificador fundamentado en procesos Gaussianos para predecir el diagnóstico individual de TDAH mediante un análisis de patrones multivariantes durante una tarea de atención, logrando una precisión global del 77%. Estos resultados han permitido establecer correlaciones entre la severidad de los síntomas y el diagnóstico, contribuyendo a una mejor comprensión de sus manifestaciones clínicas.

### 4. Objetivos

#### Objetivo General

Desarrollar una metodología de aprendizaje relacionada con registros EEG basado en un modelo fundacional, que cuantifique la incertidumbre en la inferencia e integre bases de datos etiquetadas y no etiquetadas mediante técnicas de autoaprendizaje y ajuste fino.

#### Objetivos específicos

1. Desarrollar un modelo fundacional para la clasificación de señales biológicas relacionadas con registros EEG, que aproveche datos no etiquetados en la etapa de autoaprendizaje y datos etique-

tados para su ajuste fino.

2. Implementar una herramienta de predicción estocástica basada en procesos Gaussianos, que permita modelar la incertidumbre en la predicción del modelo fundacional.
3. Diseñar una estrategia para manejar la variabilidad e inconsistencia en conjuntos de datos de registros EEG, permitiendo la integración efectiva de bases de datos con diversos estándares para su aprovechamiento en el modelo.

## 5. Metodología

Para dar cumplimiento a cada uno de los objetivos específicos, se propone la siguiente metodología, la cual estará dividida en tres fases (una por cada objetivo):

### Fase 1: Diseño y Desarrollo del Modelo Fundacional para la Clasificación de Señales EEG

**Objetivo específico 1:** Diseñar y desarrollar un modelo fundacional para la clasificación de señales biológicas relacionadas con registros EEG, que aproveche datos no etiquetados en la etapa de autoaprendizaje y datos etiquetados para su ajuste fino.

#### 1. Actividad 1.1: Recopilación y Preprocesamiento de Datos EEG

Se recopilará un conjunto de registros EEG, provenientes de diversas fuentes, y se organizarán tanto bases de datos etiquetadas como no etiquetadas. Se realizará un preprocesamiento inicial que incluya la eliminación de artefactos, la normalización de los datos y la sincronización de las señales para asegurar la homogeneidad en la tasa de muestreo y el número de canales.

#### 2. Actividad 1.2: Desarrollo del Modelo Fundacional

Se diseñará y desarrollará un modelo fundacional empleando técnicas de autoaprendizaje para extraer representaciones generales de las señales EEG. Posteriormente, se aplicará un ajuste fino utilizando los datos etiquetados para optimizar la capacidad del modelo en la clasificación de individuos con trastornos mentales.

#### 3. Actividad 1.3: Validación Interna del Modelo

Se validará el desempeño del modelo fundacional mediante métricas de clasificación. Se ajustarán los hiperparámetros en función de los resultados obtenidos, garantizando la adaptabilidad del modelo a nuevos escenarios clínicos.

### Fase 2: Implementación de la Herramienta de Predicción Estocástica Basada en Procesos Gaussianos

**Objetivo específico 2:** Implementar una herramienta de predicción estocástica basada en procesos Gaussianos, que permita modelar la incertidumbre en la predicción del modelo fundacional.

#### 1. Actividad 2.1: Investigación de Procesos Gaussianos para Modelar Incertidumbre

Realizar una revisión bibliográfica sobre técnicas basadas en procesos Gaussianos en el ámbito de datos biomédicos y EEG, identificando métodos adecuados para cuantificar la incertidumbre en las predicciones.

#### 2. Actividad 2.2: Integración del Componente Gaussianos en el Modelo

Desarrollar e integrar en el modelo fundacional un módulo basado en procesos Gaussianos que estime la incertidumbre asociada a cada predicción, proporcionando una medida cuantitativa de la confiabilidad diagnóstica.

#### 3. Actividad 2.3: Validación de la Herramienta Estocástica

Validar la herramienta de predicción estocástica mediante pruebas en un conjunto de datos inde-

pendiente, evaluando la precisión del modelo y la utilidad de la estimación de incertidumbre para el diagnóstico y tratamiento de trastornos mentales.

### Fase 3: Elaboración de Estrategias para el Manejo de la Variabilidad en los Datos

**Objetivo específico 3:** Diseñar una estrategia para manejar la variabilidad e inconsistencia en conjuntos de datos de registros EEG, permitiendo la integración efectiva de bases de datos con diversos estándares para su aprovechamiento en el modelo.

1. **Actividad 3.1: Revisión y Análisis de la Variabilidad en los Datos EEG**

Realizar una revisión de la literatura para identificar los principales desafíos asociados a la variabilidad en los conjuntos de datos EEG, tales como valores ausentes, diferencias en la tasa de muestreo, variaciones en el número de canales y el fenómeno de dataset shift.

2. **Actividad 3.2: Integración de las técnicas de manejo de variabilidad en los datos al modelo fundacional**

Incorporar las estrategias investigadas en la fase anterior al flujo de trabajo del modelo fundacional, de manera que se optimice la capacidad del modelo para manejar señales biológicas.

3. **Actividad 3.3: Validación y Documentación de la Estrategia**

Validar la efectividad de la estrategia de manejo de variabilidades en los datos mediante pruebas comparativas con datos de EEG, y documentar el proceso que sirva de guía para la implementación y futuras mejoras.

## 6. Productos de CTe Esperados

- Un informe técnico final.
- Un artículo Q1 sometido en revista indexada.
- Un software registrado.

## Referencias

- [1] M. Dehghan-Bonari, M. Alipour-Vaezi, M. M. Nasiri, and A. Aghsami, "A diagnostic analytics model for managing post-disaster symptoms of depression and anxiety among students using a novel data-driven optimization approach," *Healthcare Analytics*, vol. 4, 12 2023.
- [2] G. Ayano, K. Yohannes, and M. Abraha, "Epidemiology of attention-deficit/hyperactivity disorder (adhd) in children and adolescents in africa: a systematic review and meta-analysis," *Annals of General Psychiatry*, vol. 19, no. 1, p. 21, Mar 2020. [Online]. Available: <https://doi.org/10.1186/s12991-020-00271-w>
- [3] S. V. Faraone, P. Asherson, T. Banaschewski, J. Biederman, J. K. Buitelaar, J. A. Ramos-Quiroga, L. A. Rohde, E. J. Sonuga-Barke, R. Tannock, and B. Franke, "Attention-deficit/hyperactivity disorder," *Nature Reviews Disease Primers*, vol. 1, 2015, cited by: 1053. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85010968595&doi=10.1038%2fnrdp.2015.20&partnerID=40&md5=af13ca755f7637047546312aaa659c2b>
- [4] A. Kivumbi, W. Byansi, C. Damulira, P. Namatovu, J. Mugisha, O. Sensoy Bahar, M. M. McKay, K. Hoagwood, and F. M. Ssewamala, "Prevalence of behavioral disorders and attention deficit/hyperactive disorder among school going children in southwestern uganda," *BMC Psychiatry*, vol. 19, no. 1, p. 105, Apr 2019. [Online]. Available: <https://doi.org/10.1186/s12888-019-2069-8>



- [5] R. Zhou, Q. Xia, H. Shen, X. Yang, Y. Zhang, and J. Xu, “Diagnosis of children’s attention deficit hyperactivity disorder (ADHD) and its association with cytomegalovirus infection with ADHD: a historical review,” *Int J Clin Exp Med*, vol. 8, no. 8, pp. 13 969–13 975, Aug. 2015.
- [6] D. C. Lohani and B. Rana, “Adhd diagnosis using structural brain mri and personal characteristic data with machine learning framework,” *Psychiatry Research: Neuroimaging*, vol. 334, p. 111689, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0925492723000999>
- [7] D. Adam, “Mental health: On the spectrum,” *Nature*, vol. 496, no. 7446, pp. 416–418, apr 2013. [Online]. Available: <https://doi.org/10.1038/496416a>
- [8] M. H. Sibley, “Empirically-informed guidelines for first-time adult adhd diagnosis,” *Journal of Clinical and Experimental Neuropsychology*, vol. 43, no. 4, pp. 340–351, 2021, PMID: 33949916. [Online]. Available: <https://doi.org/10.1080/13803395.2021.1923665>
- [9] P. Asherson, L. Leaver, M. Adamou, M. Arif, G. Askey, M. Butler, S. Cubbin, T. Newlove-Delgado, J. Kustow, J. Lanham-Cook, J. Findlay, J. Maxwell, P. Mason, H. Read, K. van Rensburg, U. Müller-Sedgwick, J. Sedgwick-Müller, and C. Skirrow, “Mainstreaming adult adhd into primary care in the uk: guidance, practice, and best practice recommendations,” *BMC Psychiatry*, vol. 22, no. 1, p. 640, Oct 2022. [Online]. Available: <https://doi.org/10.1186/s12888-022-04290-7>
- [10] S. Pallanti and L. Salerno, *The Socioeconomic Burden of Adult ADHD*. Cham: Springer International Publishing, 2020, pp. 1–20. [Online]. Available: [https://doi.org/10.1007/978-3-030-39051-8\\_1](https://doi.org/10.1007/978-3-030-39051-8_1)
- [11] M. Maniruzzaman, J. Shin, M. A. Hasan, and Y. Akira, “Efficient feature selection and machine learning based adhd detection using eeg signal,” *Computers, Materials & Continua*, vol. 72, 04 2022.
- [12] S. K. Khare and U. R. Acharya, “An explainable and interpretable model for attention deficit hyperactivity disorder in children using eeg signals,” *Computers in Biology and Medicine*, vol. 155, p. 106676, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0010482523001415>
- [13] H. W. Loh, C. P. Ooi, S. L. Oh, P. D. Barua, Y. R. Tan, U. R. Acharya, and D. S. S. Fung, “Adhd/cd-net: automated eeg-based characterization of adhd and cd using explainable deep neural network technique,” *Cognitive Neurodynamics*, vol. 18, no. 4, pp. 1609–1625, Aug 2024. [Online]. Available: <https://doi.org/10.1007/s11571-023-10028-2>
- [14] H. Jahani and A. A. Safaei, “Efficient deep learning approach for diagnosis of attention-deficit/hyperactivity disorder in children based on eeg signals,” *Cognitive Computation*, vol. 16, no. 5, pp. 2315–2330, Sep 2024. [Online]. Available: <https://doi.org/10.1007/s12559-024-10302-3>
- [15] M. Garcia-Argibay, Y. Zhang-James, S. Cortese, P. Lichtenstein, H. Larsson, and S. V. Faraone, “Predicting childhood and adolescent attention-deficit/hyperactivity disorder onset: a nationwide deep learning approach,” *Molecular Psychiatry*, vol. 28, no. 3, pp. 1232–1239, Mar 2023. [Online]. Available: <https://doi.org/10.1038/s41380-022-01918-8>
- [16] M. Moghaddari, M. Z. Lighvan, and S. Danishvar, “Diagnose adhd disorder in children using convolutional neural network based on continuous mental task eeg,” *Computer Methods and Programs in Biomedicine*, vol. 197, 2020, cited by: 100. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85090562418&doi=10.1016%2fj.cmpb.2020.105738&partnerID=40&md5=c1083c9248e2e050e47a127ec3f19889>
- [17] Z. Emam, A. Kondrich, S. Harrison, F. Lau, Y. Wang, A. Kim, and E. Branson, “On the state of data in computer vision: Human annotations remain indispensable for developing deep learning models,” 2021. [Online]. Available: <https://arxiv.org/abs/2108.00114>

- [18] N. K. Iyortsuun, S.-H. Kim, M. Jhon, H.-J. Yang, and S. Pant, “A review of machine learning and deep learning approaches on mental health diagnosis,” *Healthcare*, vol. 11, no. 3, 2023. [Online]. Available: <https://www.mdpi.com/2227-9032/11/3/285>
- [19] G. Mathew, D. Barbosa, J. Prince, and S. Venkatraman, “Foundation models for cardiovascular disease detection via biosignals from digital stethoscopes,” *npj Cardiovascular Health*, vol. 1, p. 25, 10 2024. [Online]. Available: <https://www.nature.com/articles/s44325-024-00027-5>
- [20] S. Abbaspourazad, O. Elachqar, A. C. Miller, S. Emrani, U. Nallasamy, and I. Shapiro, “Large-scale training of foundation models for wearable biosignals,” 12 2023. [Online]. Available: <http://arxiv.org/abs/2312.05409>
- [21] A. Apicella, P. Arpaia, G. D’Errico, D. Marocco, G. Mastrati, N. Moccaldi, and R. Prevete, “Toward cross-subject and cross-session generalization in eeg-based emotion recognition: Systematic review, taxonomy, and methods,” *Neurocomputing*, vol. 604, p. 128354, 2024. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0925231224011251>
- [22] B. Gutierrez Becker, T. Klein, and C. Wachinger, “Gaussian process uncertainty in age estimation as a measure of brain abnormality,” *NeuroImage*, vol. 175, pp. 246–258, 2018. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1053811918302854>
- [23] S. Saxena, M. Funk, and D. Chisholm, “World health assembly adopts comprehensive mental health action plan 2013-2020,” *Lancet*, vol. 381, no. 9882, pp. 1970–1971, Jun. 2013, pMID: 23746771.
- [24] A. Galiana-Simal, P. Vecina-Navarro, P. Sánchez-Ruiz, and M. Vela-Romero, “Electroencefalografía cuantitativa como herramienta para el diagnóstico y seguimiento del paciente con trastorno por déficit de atención/hiperactividad,” *Rev. Neurol.*, vol. 70, no. 06, p. 197, 2020.
- [25] D. A. Pineda, F. Lopera, J. D. Palacio, D. Ramirez, and G. C. Henao, “Prevalence estimations of attention-deficit/hyperactivity disorder: differential diagnoses and comorbidities in a colombian sample,” *International Journal of Neuroscience*, vol. 113, no. 1, pp. 49–71, 2003.
- [26] L. J. Llanos Lizcano *et al.*, “Trastorno por déficit de atención e hiperactividad (tdah) en niños escolarizados de 6 a 17 años,” *Pediatría Aten. Primaria*, vol. 21, no. 83, pp. e101–e108, 2019.
- [27] M. E. Narad *et al.*, “Parent–teacher agreement on adhd symptoms across development,” *Psychological Assessment*, vol. 27, no. 1, p. 239, 2015.
- [28] T. Eslami, F. Almuqhim, J. S. Raiker, and F. Saeed, “Machine learning methods for diagnosing autism spectrum disorder and attention-deficit/hyperactivity disorder using functional and structural mri: A survey,” *Frontiers in Neuroinformatics*, vol. 14, p. 575999, Jan. 2021.
- [29] Y.-L. Yeh, T.-H. Hou, and W.-Y. Chang, “An intelligent model for the classification of children’s occupational therapy problems,” *Expert Systems with Applications*, vol. 39, no. 5, pp. 5233–5242, 2012.
- [30] G. V. Polanczyk, E. G. Willcutt, G. A. Salum, C. Kieling, and L. A. Rohde, “Adhd prevalence estimates across three decades: an updated systematic review and meta-regression analysis,” *International Journal of Epidemiology*, vol. 43, no. 2, pp. 434–442, Apr. 2014.
- [31] M. E. de la Viuda Suárez, J. C. Alonso Lorenzo, F. J. Ruiz Jiménez, and M. C. Luciano Soriano, “Assessing adhd symptoms in clinical public practice: Is a reliable final diagnosis possible?” *Aten. Primaria*, vol. 53, no. 3, p. 101945, Mar. 2021.
- [32] M. R. Arbabshirani, S. Plis, J. Sui, and V. D. Calhoun, “Single subject prediction of brain disorders in neuroimaging: Promises and pitfalls,” *NeuroImage*, vol. 145, p. 137 – 165, 2017. cited by: 667. All Open Access, Bronze Open Access, Green Open Access. [Online].

- Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-84962787673&doi=10.1016%2fj.neuroimage.2016.02.079&partnerID=40&md5=02c435791465a7d077ad0db2d5ba2137>
- [33] J. D. Pastrana-Cortes, M. C. Maya-Piedrahita, P. M. Herrera-Gómez, D. Cárdenas-Peña, and A. A. Orozco-Gutierrez, “Interpretable diagnosis of adhd based on wavelet features and logistic regression,” in *Progress in Artificial Intelligence and Pattern Recognition*, Y. Hernández Heredia, V. Mi-líán Núñez, and J. Ruiz Shulcloper, Eds. Cham: Springer International Publishing, 2021, pp. 424–433.
- [34] C. J. Vaidya, X. You, S. Mostofsky, F. Pereira, M. M. Berl, and L. Kenworthy, “Data-driven identification of subtypes of executive function across typical development, attention deficit hyperactivity disorder, and autism spectrum disorders,” *Journal of Child Psychology and Psychiatry and Allied Disciplines*, vol. 61, no. 1, p. 51 – 61, 2020, cited by: 71; All Open Access, Green Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85072172828&doi=10.1111%2fjcpp.13114&partnerID=40&md5=2c19801a420c8a611573b09d2a121f06>
- [35] H. T. Tor, C. P. Ooi, N. S. Lim-Ashworth, J. K. E. Wei, V. Jahmunah, S. L. Oh, U. R. Acharya, and D. S. S. Fung, “Automated detection of conduct disorder and attention deficit hyperactivity disorder using decomposition and nonlinear techniques with eeg signals,” *Computer Methods and Programs in Biomedicine*, vol. 200, 2021, cited by: 93. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85099615028&doi=10.1016%2fj.cmpb.2021.105941&partnerID=40&md5=be182f5ba2f9cd1a27831fe3a7ded6dc>
- [36] E.-A. Paraschiv, M. Ianculescu, and A. Alexandru, “Bridging the gap: Deep learning eeg-based applications for schizophrenia classification and management,” vol. 109, 2024, Conference paper, p. 676 – 684, cited by: 0. [Online]. Available: [https://www.scopus.com/inward/record.uri?eid=2-s2.0-85210073213&doi=10.1007%2f978-3-031-62502-2\\_76&partnerID=40&md5=6c97da2b0b743f44999242993d3daed3](https://www.scopus.com/inward/record.uri?eid=2-s2.0-85210073213&doi=10.1007%2f978-3-031-62502-2_76&partnerID=40&md5=6c97da2b0b743f44999242993d3daed3)
- [37] G. Arji, L. Erfannia, S. alirezai, and M. Hemmat, “A systematic literature review and analysis of deep learning algorithms in mental disorders,” *Informatics in Medicine Unlocked*, vol. 40, 2023, cited by: 7; All Open Access, Gold Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85161681016&doi=10.1016%2fj.imu.2023.101284&partnerID=40&md5=b1a369fb778fd6fcb1a2623f0cc92eeb>
- [38] A. Ahmadi, M. Kashefi, H. Shahrokhi, and M. A. Nazari, “Computer aided diagnosis system using deep convolutional neural networks for adhd subtypes,” *Biomedical Signal Processing and Control*, vol. 63, p. 102227, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1746809420303578>
- [39] S. Zhang and D. Metaxas, “On the challenges and perspectives of foundation models for medical image analysis,” *Medical Image Analysis*, vol. 91, 2024, cited by: 35; All Open Access, Green Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85175172380&doi=10.1016%2fj.media.2023.102996&partnerID=40&md5=9e238dcfdad07138a235e852d56bf7d0>
- [40] D. Wang, X. Wang, L. Wang, M. Li, Q. Da, X. Liu, X. Gao, J. Shen, J. He, T. Shen, Q. Duan, J. Zhao, K. Li, Y. Qiao, and S. Zhang, “A real-world dataset and benchmark for foundation model adaptation in medical image classification,” *Scientific Data*, vol. 10, no. 1, 2023, cited by: 10; All Open Access, Gold Open Access, Green Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85169682108&doi=10.1038%2fs41597-023-02460-0&partnerID=40&md5=e491975ddc9a5c14fa6e033a2d878f30>
- [41] S. Abbaspourazad, O. Elachqar, A. C. Miller, S. Emrani, U. Nallasamy, and I. Shapiro, “Large-scale training of foundation models for wearable biosignals,” 2024, Conference paper, cited

- by: 2. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85199807514&partnerID=40&md5=151326ca004a05961164e60923cad4a0>
- [42] L. Lim, A. Marquand, A. A. Cubillo, A. B. Smith, K. Chantiluke, A. Simmons, M. Mehta, and K. Rubia, "Disorder-specific predictive classification of adolescents with attention deficit hyperactivity disorder (adhd) relative to autism using structural magnetic resonance imaging," *PLoS ONE*, vol. 8, no. 5, 2013, cited by: 87; All Open Access, Gold Open Access, Green Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-84877826499&doi=10.1371%2Fjournal.pone.0063660&partnerID=40&md5=e31429216c7db29697c5c53ddac19103>
- [43] H. Hart, K. Chantiluke, A. I. Cubillo, A. B. Smith, A. Simmons, M. J. Brammer, A. F. Marquand, and K. Rubia, "Pattern classification of response inhibition in adhd: Toward the development of neurobiological markers for adhd," *Human Brain Mapping*, vol. 35, no. 7, p. 3083 – 3094, 2014, cited by: 98; All Open Access, Green Open Access, Hybrid Gold Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-84902213440&doi=10.1002%2fhbm.22386&partnerID=40&md5=d65b9f9465a4be890498a36781cd6bb2>

## Referencias

- [Baltrusaitis et al., 2019] Baltrusaitis, T., Ahuja, C., and Morency, L. P. (2019). Multimodal machine learning: A survey and taxonomy.
- [Garbarino et al., 2014] Garbarino, M., Lai, M., Bender, D., Picard, R. W., and Tognetti, S. (2014). Empatica e3 – a wearable wireless multi-sensor device for real-time computerized biofeedback and data acquisition. In *Proceedings of the International Conference on Wireless Mobile Communication and Healthcare (ICWMCHM)*, pages 39–42.
- [Giraldo and Alvarez, 2021] Giraldo, J.-J. and Alvarez, M. A. (2021). A fully natural gradient scheme for improving inference of the heterogeneous multioutput gaussian process model. *IEEE Transactions on Neural Networks and Learning Systems*, 33(11):6429–6442.
- [Li et al., 2021] Li, Q., Tan, J., Wang, J., and Chen, H. (2021). A multimodal event-driven lstm model for stock prediction using online news. *IEEE Transactions on Knowledge and Data Engineering*, 33(10):3323 – 3337. Cited by: 122; All Open Access, Bronze Open Access.
- [Liang et al., 2024] Liang, P. P., Zadeh, A., and Morency, L. P. (2024). Foundations & trends in multimodal machine learning: Principles, challenges, and open questions. *ACM Computing Surveys*, 56.
- [Salimbeni et al., 2018] Salimbeni, H., Eleftheriadis, S., and Hensman, J. (2018). Natural gradients in practice: Non-conjugate variational inference in gaussian process models. In Storkey, A. and Perez-Cruz, F., editors, *Proceedings of the Twenty-First International Conference on Artificial Intelligence and Statistics*, volume 84 of *Proceedings of Machine Learning Research*, pages 689–697. PMLR.
- [Svoren et al., 2020] Svoren, H., Thambawita, V., Halvorsen, P., Jakobsen, P., Garcia-Ceja, E., Noori, F. M., Hammer, H. L., Lux, M., Riegler, M. A., and Hicks, S. A. (2020). Toadstool: A dataset for training emotional intelligent machines playing super mario bros. In *Proceedings of the 11th ACM Multimedia Systems Conference, MMSys '20*, page 309–314, New York, NY, USA. Association for Computing Machinery.
- [Venugopalan et al., 2021] Venugopalan, J., Tong, L., Hassanzadeh, H. R., and Wang, M. D. (2021). Multimodal deep learning models for early detection of alzheimer’s disease stage. *Scientific Reports*, 11.
- [Vos et al., 2023] Vos, G., Trinh, K., Sarnyai, Z., and Azghadi, M. R. (2023). Generalizable machine learning for stress monitoring from wearable devices: A systematic literature review.
- [Wan et al., 2020] Wan, S., Qi, L., Xu, X., Tong, C., and Gu, Z. (2020). Deep learning models for real-time human activity recognition with smartphones. *Mobile Networks and Applications*, 25(2):743 – 755. Cited by: 470.
- [Yang et al., 2023a] Yang, K., Wang, C., Gu, Y., Sarsenbayeva, Z., Tag, B., Dingler, T., Wadley, G., and Gonçalves, J. (2023a). Behavioral and physiological signals-based deep multimodal approach for mobile emotion recognition. *IEEE Transactions on Affective Computing*, 14:1082–1097.
- [Yang et al., 2023b] Yang, K., Wang, C., Gu, Y., Sarsenbayeva, Z., Tag, B., Dingler, T., Wadley, G., and Gonçalves, J. (2023b). Behavioral and physiological signals-based deep multimodal approach for mobile emotion recognition. *IEEE Transactions on Affective Computing*, 14(2):1082 – 1097. Cited by: 45.
- [Zhang and Etemad, 2021] Zhang, G. and Etemad, A. (2021). Capsule attention for multimodal eeg-eog representation learning with application to driver vigilance estimation. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 29:1138 – 1149. Cited by: 65; All Open Access, Gold Open Access, Green Open Access.
- [Zhu et al., 2023] Zhu, L., Spachos, P., Ng, P. C., Yu, Y., Wang, Y., Plataniotis, K., and Hatzinakos, D. (2023). Stress detection through wrist-based electrodermal activity monitoring and machine learning. *IEEE Journal of Biomedical and Health Informatics*, 27:2155–2165.