

Integración de Modelos Fundacionales y Procesos Gaussianos para el Apoyo al Diagnóstico y Tratamiento de Trastornos Mentales a partir de Señales Electroencefalográficas .

Julián David Pastrana Cortés, M.Sc.

Resumen

El diagnóstico de trastornos mentales y algunas terapias tradicionalmente se basan en evaluaciones clínicas, entrevistas y pruebas estandarizadas, lo cual puede conllevar interpretaciones subjetivas y requerir un seguimiento prolongado. Además, la generación de modelos de inteligencia artificial que apoyen la práctica clínica suele depender de grandes volúmenes de datos etiquetados, restringe su transferencia a ambientes reales. En este contexto, el presente proyecto propone el desarrollo de un modelo fundacional estocástico basado en procesos Gaussianos para el entrenamiento de modelos de Inteligencia Artificial (IA) a partir de múltiples bases de datos de señales electroencefalográficas (EEG) con características de adquisición variantes, que integre datos no etiquetados mediante técnicas de autoaprendizaje y datos etiquetados para su ajuste fino. Este enfoque no solo busca extraer representaciones generales a partir de la estructura de las señales biológicas, sino que también incorpora un componente que modela la incertidumbre en las predicciones, ofreciendo una medida cuantitativa de la confiabilidad del modelo. Se espera que los resultados impulsen la generación de nuevo conocimiento y la innovación en los ámbitos de la salud, la ingeniería y la ciencia.

Abstract

The diagnosis of mental disorders and certain therapies have traditionally relied on clinical evaluations, interviews, and standardized tests, which can lead to subjective interpretations and require prolonged follow-up. Moreover, the development of artificial intelligence models that support clinical practice typically depends on large volumes of labeled data, limiting their transfer to real-world settings. In this context, the present project proposes the development of a stochastic foundational model based on Gaussian processes for training AI models using multiple databases of electroencephalographic (EEG) signals with varying acquisition characteristics. This model integrates unlabeled data through self-learning techniques and labeled data for fine-tuning. This approach not only seeks to extract general representations from the structure of biological signals but also incorporates a component that models prediction uncertainty, providing a quantitative measure of the model's reliability. It is expected that the results will spur the generation of new knowledge and innovation in the fields of health, engineering, and science.

1. Planteamiento del problema y pregunta de investigación

Los trastornos mentales afectan la cognición, el comportamiento y las emociones de millones de personas en el mundo. Se estima que alrededor de 350 millones de individuos padecen algún trastorno mental [1]. La impulsividad, como característica sintomática central, está presente en diversas condiciones mentales, entre las que destacan el Trastorno Negativista Desafiante (TND), el Trastorno de Desregulación del Estado de Ánimo Disruptivo (TDEAD) y el Trastorno Bipolar (TB). Dentro de este grupo, el Trastorno por Déficit de Atención e Hiperactividad (TDAH) representa un desafío clínico significativo, con una prevalencia aproximada del 5 % en población infantil y adolescente, y del 2.5 % en adultos, constituyendo así uno de los trastornos neuropsiquiátricos más comunes durante la infancia y la adolescencia.

Estos trastornos no solo dificultan el rendimiento académico y laboral [2], sino que también aumenta el riesgo de presentar otros problemas psiquiátricos, conductas delictivas y adicciones [3].

La detección e intervención temprana de la impulsividad es esencial para brindar un tratamiento oportuno y efectivo [4]. Sin embargo, las técnicas diagnósticas actuales presentan limitaciones importantes: muchas pruebas requieren un seguimiento prolongado [5], pueden estar sujetas a interpretaciones subjetivas [6], omitirse debido a la gran variación en las presentaciones clínicas y síntomas [7], y muchos criterios resultan ineficientes para el diagnóstico en adultos [8]. Además, el acceso a un tratamiento clínico y seguimiento es frecuentemente restringido debido a la falta de recursos o la escasez de especialistas [9, 10].

El avance en el desarrollo de modelos de aprendizaje automático ha permitido la creación de herramientas que apoyan el diagnóstico y tratamiento de diversas enfermedades neurológicas y trastornos mentales [11]. Generalmente, estos modelos utilizan señales electroencefalográficas (EEG) para clasificar registros según la presencia o ausencia de la enfermedad, mediante un enfoque de clasificación binaria. No obstante, la naturaleza no estacionaria y la complejidad inherente a las señales EEG complican su análisis utilizando modelos tradicionales [12, 13].

El uso de técnicas de aprendizaje profundo se presenta como una alternativa prometedora, ya que permite extraer características abstractas de las señales EEG mediante una gran cantidad de parámetros [14, 15, 16]. No obstante, el entrenamiento de estos modelos demanda grandes volúmenes de datos etiquetados en un entorno supervisado, lo cual frecuentemente es costoso o inviable, y su potencial mejora se ve limitada por la falta de interpretabilidad [17, 18].

Para superar esta limitación, han surgido los modelos fundacionales, que permiten preentrenar con conjuntos de datos no etiquetados y, posteriormente, ajustar el modelo para tareas específicas utilizando una cantidad significativamente menor de datos etiquetados [19, 20]. Este enfoque aprovecha la estructura subyacente presente en datos sin clasificar, permitiendo que el modelo aprenda representaciones generales robustas. Gracias a este preentrenamiento, el modelo puede transferir conocimientos a tareas concretas, lo que reduce la dependencia de grandes volúmenes de datos anotados y agiliza el proceso de adaptación a nuevos escenarios.

Un aspecto relevante en el preentrenamiento de estos modelos es la variabilidad inherente a los conjuntos de datos no etiquetados. Estas bases de datos pueden diferir en los estándares de adquisición, lo que se manifiesta en la presencia de valores ausentes, variaciones en la tasa de muestreo, diferencias en el número de canales e incluso problemas de generalización al cambiar de sujetos o sesiones (conocido como Dataset Shift) [21]. Descartar estos datos supondría la pérdida de información potencialmente valiosa; por ello, es importante desarrollar un modelo fundacional capaz de gestionar eficazmente dichas inconsistencias y maximizar el aprovechamiento de los datos disponibles.

Lo anterior también induce una incertidumbre en el modelo, por lo que en el ámbito clínico no es suficiente obtener una predicción puntual en el diagnóstico, sino también disponer de una medida de la incertidumbre asociada que cuantifique el nivel de riesgo a la hora de tomar una decisión basada en la inferencia del modelo. En este sentido, los procesos Gaussianos ofrecen una solución al generar una distribución de probabilidad predictiva mediante un enfoque Bayesiano en lugar de una predicción puntual [22, 14]. Sin embargo, la integración de procesos Gaussianos con modelos fundacionales aún es un área poco explorada y con un gran potencial de mejora.

Pregunta de investigación: ¿Cómo desarrollar un modelo fundacional estocástico para la inferencia a partir de señales biológicas que integre procesos Gaussianos, para el soporte a la práctica clínica mediante el análisis de señales EEG, considerando la variabilidad e inconsistencias presentes en los conjuntos de datos?

2. Justificación

Desde el ámbito de la salud pública, los trastornos mentales son considerados una prioridad mundial debido a sus implicaciones en el desarrollo social. Su presencia está asociada con el fracaso escolar, comportamientos antisociales e incluso delincuencia. Estos presentan subtipos según su gravedad: leve, moderado o grave. Su etiología está relacionada con factores genéticos, neurobiológicos, prenatales, perinatales y posnatales, cuya interacción contribuye a su manifestación clínica [23].

El Plan Nacional de Desarrollo 2022-2026 (PND), Colombia Potencia Mundial de la Vida, busca trabajar mediante un enfoque preventivo y predictivo, estrategias orientadas a promover la capacidad de agencia y cuidado de la salud. En su sección, Salud y bienestar para las juventudes, propone fomentar el bienestar mental, con el objetivo de abordar las causas que inciden en la salud mental de los jóvenes y fomentar las prácticas profesionales que potencien su acompañamiento.

Por su parte, el CONPES 3992 establece estrategias para la promoción de la salud mental, incluyendo la investigación y la integración de sistemas de información en el área. En particular, el Departamento Nacional de Planeación (DNP) desarrolla un modelo predictor de determinantes sociales incidentes en la salud mental para orientar políticas de promoción. Asimismo, el Ministerio de Salud y Protección Social promueve estrategias para la atención en salud e inclusión social.

Solamente la prevalencia mundial del TDAH oscila entre el 5 % y 10 % en niños en edad escolar [24], en Colombia se han reportado valores del 15-17 %, ubicándose entre las cifras más altas de Latinoamérica [25]. Se estima que la prevalencia por rango de edad es del 62 % en niños entre 6 y 11 años, debido a alteraciones en la maduración cerebral, lo que se traduce en un retraso de entre 2 y 3 años con respecto a niños sin la condición [26].

El diagnóstico de los trastornos mentales se basa en los criterios del DSM-5, a partir de información aportada por el paciente o su entorno sobre síntomas percibidos de inatención, impulsividad e hiperactividad, los cuales deben mantenerse durante al menos seis meses, no ser acordes al nivel de desarrollo y afectar el desempeño social, académico o laboral. Sin embargo, la ponderación subjetiva de los síntomas conlleva restricciones como discrepancias en las percepciones entre padres, maestros y profesionales [27], la variabilidad e inconsistencia en la adopción de guías clínicas y criterios insuficientes del DSM-5 [28, 29]. Además, la cobertura diagnóstica es limitada: solo el 7.4 % de los casos recibe confirmación mediante entrevista psiquiátrica estructurada, y solo el 6.6 % recibe tratamiento [30], lo que genera una alta tasa de diagnósticos erróneos en la población infantil de la región [31].

Paralelamente, se han desarrollado plataformas digitales e interfaces avanzadas para la interacción con pacientes, las cuales pueden facilitar el diagnóstico y tratamiento de diversas patologías. Entre estas, los videojuegos han cobrado relevancia como herramientas asistenciales, debido a su capacidad para mejorar la flexibilidad cognitiva y la memoria de trabajo, aspectos clave en la atención y concentración. La Política Nacional de Ciencia, Tecnología e Innovación 2021–2030 fomenta el desarrollo de tecnologías innovadoras en este ámbito. En este contexto, el grupo de investigación en Automática ha desarrollado un amplio trabajo en áreas relacionadas con el análisis de señales biológicas, el modelado de procesos estocásticos y el aprendizaje automático, con aplicaciones en el ámbito de la salud y los trastornos mentales. Además, cuenta con equipos clínicos especializados para la adquisición y análisis de registros EEG.

En conclusión, es necesario fortalecer los programas de salud mental infantil para detectar a tiempo los factores asociados a los trastornos mentales y mejorar los indicadores de prevalencia. Además, resulta importante optimizar la calidad en el diagnóstico, evaluación e intervención de los pacientes. En este sentido, esta propuesta se enfoca en enfrentar estos desafíos, reconociendo que se trata de un problema de salud pública de gran magnitud, mediante el desarrollo de una herramienta de apoyo para el diagnóstico y tratamiento de trastornos mentales a partir de señales EEG, que no solo contribuya a generar nuevos conocimientos, sino que también impulse la innovación en los sectores de la salud, la ingeniería y la

ciencia.

3. Estado del arte

Diversos modelos de aprendizaje automático han sido propuestos para apoyar el diagnóstico de trastornos mentales, como la esquizofrenia, alzheimer, depresión y autismo [32]. Por ejemplo, en [33] se implementó un modelo basado en un regresor logístico que utiliza la transformada wavelet para la clasificación de registros electroencefalográficos, permitiendo resaltar características relevantes. Asimismo, en [34] se utilizaron máquinas de soporte vectorial, las cuales ofrecen resultados interpretables para orientar las decisiones clínicas. Además, en [35] se presentó un sistema automatizado de clasificación para diferenciar entre diferentes trastornos mentales, utilizando técnicas de descomposición para extraer características discriminatorias.

Por otro lado, en [36] se implementaron modelos de aprendizaje profundo, combinando capas convolucionales y de memoria LSTM, evidenciando su potencial en la evaluación de la esquizofrenia. Además, en [37] se empleó una arquitectura basada en redes neuronales convolucionales, revelando su utilidad en análisis en la depresión y el estado de ánimo. Por último, en [38] se propone una red convolucional profunda para extraer características discriminatorias y distinguir entre dos subtipos de trastornos mentales, logrando una precisión cercana al 99.46%.

Por su parte, los modelos fundacionales emergen como herramientas de inteligencia artificial preentrenadas a gran escala, capaces de adaptarse a tareas específicas y, en consecuencia, de posibilitar diagnósticos personalizados en el ámbito clínico. En [39] se ilustra un amplio espectro de modelos fundacionales aplicados a la medicina, evidenciando su potencial en aplicaciones de salud basadas en imágenes. Asimismo, en [40] se proponen estos modelos para la clasificación de imágenes provenientes de múltiples fuentes, logrando un rendimiento aceptable y eficiencia en términos de costo para aplicaciones clínicas. Además, en [41] se demuestra que el empleo de aprendizaje auto-supervisado aplicado a grandes volúmenes de datos de fotopletimografía y electrocardiograma permite entrenar modelos fundacionales capaces de extraer información relevante sobre el estado de salud de los usuarios, lo que facilita la detección temprana de la enfermedad y el seguimiento de sus comorbilidades.

Los procesos Gaussianos han sido ampliamente utilizados en diversos estudios para mejorar la precisión en el diagnóstico y la comprensión de los trastornos mentales, aprovechando sus propiedades no paramétricas y estocásticas. Por ejemplo, en [42] se implementó un clasificador basado en este modelo, el cual empleó datos relativos al volumen de la materia gris para discriminar entre individuos sanos, alcanzando una precisión cercana al 79.3%. De manera similar, en [43] se aplicó un clasificador fundamentado en procesos Gaussianos para predecir el diagnóstico individual de TDAH mediante un análisis de patrones multivariantes durante una tarea de atención, logrando una precisión global del 77%. Estos resultados han permitido establecer correlaciones entre la severidad de los síntomas y el diagnóstico, contribuyendo a una mejor comprensión de sus manifestaciones clínicas.

4. Objetivos

Objetivo General

Desarrollar una metodología de aprendizaje relacionada con registros EEG basado en un modelo fundacional, que cuantifique la incertidumbre en la inferencia e integre bases de datos etiquetadas y no etiquetadas mediante técnicas de autoaprendizaje y ajuste fino.

Objetivos específicos

1. Desarrollar un modelo fundacional para la clasificación de señales biológicas relacionadas con registros EEG, que aproveche datos no etiquetados en la etapa de autoaprendizaje y datos etique-

tados para su ajuste fino.

2. Implementar una herramienta de predicción estocástica basada en procesos Gaussianos, que permita modelar la incertidumbre en la predicción del modelo fundacional.
3. Diseñar una estrategia para manejar la variabilidad e inconsistencia en conjuntos de datos de registros EEG, permitiendo la integración efectiva de bases de datos con diversos estándares para su aprovechamiento en el modelo.

5. Metodología

Para dar cumplimiento a cada uno de los objetivos específicos, se propone la siguiente metodología, la cual estará dividida en tres fases (una por cada objetivo):

Fase 1: Diseño y Desarrollo del Modelo Fundacional para la Clasificación de Señales EEG

Objetivo específico 1: Diseñar y desarrollar un modelo fundacional para la clasificación de señales biológicas relacionadas con registros EEG, que aproveche datos no etiquetados en la etapa de autoaprendizaje y datos etiquetados para su ajuste fino.

1. Actividad 1.1: Recopilación y Preprocesamiento de Datos EEG

Se recopilará un conjunto de registros EEG, provenientes de diversas fuentes, y se organizarán tanto bases de datos etiquetadas como no etiquetadas. Se realizará un preprocesamiento inicial que incluya la eliminación de artefactos, la normalización de los datos y la sincronización de las señales para asegurar la homogeneidad en la tasa de muestreo y el número de canales.

2. Actividad 1.2: Desarrollo del Modelo Fundacional

Se diseñará y desarrollará un modelo fundacional empleando técnicas de autoaprendizaje para extraer representaciones generales de las señales EEG. Posteriormente, se aplicará un ajuste fino utilizando los datos etiquetados para optimizar la capacidad del modelo en la clasificación de individuos con trastornos mentales.

3. Actividad 1.3: Validación Interna del Modelo

Se validará el desempeño del modelo fundacional mediante métricas de clasificación. Se ajustarán los hiperparámetros en función de los resultados obtenidos, garantizando la adaptabilidad del modelo a nuevos escenarios clínicos.

Fase 2: Implementación de la Herramienta de Predicción Estocástica Basada en Procesos Gaussianos

Objetivo específico 2: Implementar una herramienta de predicción estocástica basada en procesos Gaussianos, que permita modelar la incertidumbre en la predicción del modelo fundacional.

1. Actividad 2.1: Investigación de Procesos Gaussianos para Modelar Incertidumbre

Realizar una revisión bibliográfica sobre técnicas basadas en procesos Gaussianos en el ámbito de datos biomédicos y EEG, identificando métodos adecuados para cuantificar la incertidumbre en las predicciones.

2. Actividad 2.2: Integración del Componente Gaussianos en el Modelo

Desarrollar e integrar en el modelo fundacional un módulo basado en procesos Gaussianos que estime la incertidumbre asociada a cada predicción, proporcionando una medida cuantitativa de la confiabilidad diagnóstica.

3. Actividad 2.3: Validación de la Herramienta Estocástica

Validar la herramienta de predicción estocástica mediante pruebas en un conjunto de datos inde-

pendiente, evaluando la precisión del modelo y la utilidad de la estimación de incertidumbre para el diagnóstico y tratamiento de trastornos mentales.

Fase 3: Elaboración de Estrategias para el Manejo de la Variabilidad en los Datos

Objetivo específico 3: Diseñar una estrategia para manejar la variabilidad e inconsistencia en conjuntos de datos de registros EEG, permitiendo la integración efectiva de bases de datos con diversos estándares para su aprovechamiento en el modelo.

1. Actividad 3.1: Revisión y Análisis de la Variabilidad en los Datos EEG

Realizar una revisión de la literatura para identificar los principales desafíos asociados a la variabilidad en los conjuntos de datos EEG, tales como valores ausentes, diferencias en la tasa de muestreo, variaciones en el número de canales y el fenómeno de dataset shift.

2. Actividad 3.2: Integración de las técnicas de manejo de variabilidad en los datos al modelo fundacional

Incorporar las estrategias investigadas en la fase anterior al flujo de trabajo del modelo fundacional, de manera que se optimice la capacidad del modelo para manejar señales biológicas.

3. Actividad 3.3: Validación y Documentación de la Estrategia

Validar la efectividad de la estrategia de manejo de variabilidades en los datos mediante pruebas comparativas con datos de EEG, y documentar el proceso que sirva de guía para la implementación y futuras mejoras.

6. Productos de CTe Esperados

- Un informe técnico final.
- Un artículo Q1 sometido en revista indexada.
- Un software registrado.

Referencias

- [1] M. Dehghan-Bonari, M. Alipour-Vaezi, M. M. Nasiri, and A. Aghsami, "A diagnostic analytics model for managing post-disaster symptoms of depression and anxiety among students using a novel data-driven optimization approach," *Healthcare Analytics*, vol. 4, 12 2023.
- [2] G. Ayano, K. Yohannes, and M. Abraha, "Epidemiology of attention-deficit/hyperactivity disorder (adhd) in children and adolescents in africa: a systematic review and meta-analysis," *Annals of General Psychiatry*, vol. 19, no. 1, p. 21, Mar 2020. [Online]. Available: <https://doi.org/10.1186/s12991-020-00271-w>
- [3] S. V. Faraone, P. Asherson, T. Banaschewski, J. Biederman, J. K. Buitelaar, J. A. Ramos-Quiroga, L. A. Rohde, E. J. Sonuga-Barke, R. Tannock, and B. Franke, "Attention-deficit/hyperactivity disorder," *Nature Reviews Disease Primers*, vol. 1, 2015, cited by: 1053. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85010968595&doi=10.1038%2fnrdp.2015.20&partnerID=40&md5=af13ca755f7637047546312aaa659c2b>
- [4] A. Kivumbi, W. Byansi, C. Damulira, P. Namatovu, J. Mugisha, O. Sensoy Bahar, M. M. McKay, K. Hoagwood, and F. M. Ssewamala, "Prevalence of behavioral disorders and attention deficit/hyperactive disorder among school going children in southwestern uganda," *BMC Psychiatry*, vol. 19, no. 1, p. 105, Apr 2019. [Online]. Available: <https://doi.org/10.1186/s12888-019-2069-8>

- [5] R. Zhou, Q. Xia, H. Shen, X. Yang, Y. Zhang, and J. Xu, "Diagnosis of children's attention deficit hyperactivity disorder (ADHD) and its association with cytomegalovirus infection with ADHD: a historical review," *Int J Clin Exp Med*, vol. 8, no. 8, pp. 13 969–13 975, Aug. 2015.
- [6] D. C. Lohani and B. Rana, "Adhd diagnosis using structural brain mri and personal characteristic data with machine learning framework," *Psychiatry Research: Neuroimaging*, vol. 334, p. 111689, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0925492723000999>
- [7] D. Adam, "Mental health: On the spectrum," *Nature*, vol. 496, no. 7446, pp. 416–418, apr 2013. [Online]. Available: <https://doi.org/10.1038/496416a>
- [8] M. H. Sibley, "Empirically-informed guidelines for first-time adult adhd diagnosis," *Journal of Clinical and Experimental Neuropsychology*, vol. 43, no. 4, pp. 340–351, 2021, PMID: 33949916. [Online]. Available: <https://doi.org/10.1080/13803395.2021.1923665>
- [9] P. Asherson, L. Leaver, M. Adamou, M. Arif, G. Askey, M. Butler, S. Cubbin, T. Newlove-Delgado, J. Kustow, J. Lanham-Cook, J. Findlay, J. Maxwell, P. Mason, H. Read, K. van Rensburg, U. Müller-Sedgwick, J. Sedgwick-Müller, and C. Skirrow, "Mainstreaming adult adhd into primary care in the uk: guidance, practice, and best practice recommendations," *BMC Psychiatry*, vol. 22, no. 1, p. 640, Oct 2022. [Online]. Available: <https://doi.org/10.1186/s12888-022-04290-7>
- [10] S. Pallanti and L. Salerno, *The Socioeconomic Burden of Adult ADHD*. Cham: Springer International Publishing, 2020, pp. 1–20. [Online]. Available: https://doi.org/10.1007/978-3-030-39051-8_1
- [11] M. Maniruzzaman, J. Shin, M. A. Hasan, and Y. Akira, "Efficient feature selection and machine learning based adhd detection using eeg signal," *Computers, Materials & Continua*, vol. 72, 04 2022.
- [12] S. K. Khare and U. R. Acharya, "An explainable and interpretable model for attention deficit hyperactivity disorder in children using eeg signals," *Computers in Biology and Medicine*, vol. 155, p. 106676, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0010482523001415>
- [13] H. W. Loh, C. P. Ooi, S. L. Oh, P. D. Barua, Y. R. Tan, U. R. Acharya, and D. S. S. Fung, "Adhd/cd-net: automated eeg-based characterization of adhd and cd using explainable deep neural network technique," *Cognitive Neurodynamics*, vol. 18, no. 4, pp. 1609–1625, Aug 2024. [Online]. Available: <https://doi.org/10.1007/s11571-023-10028-2>
- [14] H. Jahani and A. A. Safaei, "Efficient deep learning approach for diagnosis of attention-deficit/hyperactivity disorder in children based on eeg signals," *Cognitive Computation*, vol. 16, no. 5, pp. 2315–2330, Sep 2024. [Online]. Available: <https://doi.org/10.1007/s12559-024-10302-3>
- [15] M. Garcia-Argibay, Y. Zhang-James, S. Cortese, P. Lichtenstein, H. Larsson, and S. V. Faraone, "Predicting childhood and adolescent attention-deficit/hyperactivity disorder onset: a nationwide deep learning approach," *Molecular Psychiatry*, vol. 28, no. 3, pp. 1232–1239, Mar 2023. [Online]. Available: <https://doi.org/10.1038/s41380-022-01918-8>
- [16] M. Moghaddari, M. Z. Lighvan, and S. Danishvar, "Diagnose adhd disorder in children using convolutional neural network based on continuous mental task eeg," *Computer Methods and Programs in Biomedicine*, vol. 197, 2020, cited by: 100. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85090562418&doi=10.1016%2fj.cmpb.2020.105738&partnerID=40&md5=c1083c9248e2e050e47a127ec3f19889>
- [17] Z. Emam, A. Kondrich, S. Harrison, F. Lau, Y. Wang, A. Kim, and E. Branson, "On the state of data in computer vision: Human annotations remain indispensable for developing deep learning models," 2021. [Online]. Available: <https://arxiv.org/abs/2108.00114>

- [18] N. K. Iyortsuun, S.-H. Kim, M. Jhon, H.-J. Yang, and S. Pant, “A review of machine learning and deep learning approaches on mental health diagnosis,” *Healthcare*, vol. 11, no. 3, 2023. [Online]. Available: <https://www.mdpi.com/2227-9032/11/3/285>
- [19] G. Mathew, D. Barbosa, J. Prince, and S. Venkatraman, “Foundation models for cardiovascular disease detection via biosignals from digital stethoscopes,” *npj Cardiovascular Health*, vol. 1, p. 25, 10 2024. [Online]. Available: <https://www.nature.com/articles/s44325-024-00027-5>
- [20] S. Abbaspourazad, O. Elachqar, A. C. Miller, S. Emrani, U. Nallasamy, and I. Shapiro, “Large-scale training of foundation models for wearable biosignals,” 12 2023. [Online]. Available: <http://arxiv.org/abs/2312.05409>
- [21] A. Apicella, P. Arpaia, G. D’Errico, D. Marocco, G. Mastrati, N. Moccaldi, and R. Prevete, “Toward cross-subject and cross-session generalization in eeg-based emotion recognition: Systematic review, taxonomy, and methods,” *Neurocomputing*, vol. 604, p. 128354, 2024. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0925231224011251>
- [22] B. Gutierrez Becker, T. Klein, and C. Wachinger, “Gaussian process uncertainty in age estimation as a measure of brain abnormality,” *NeuroImage*, vol. 175, pp. 246–258, 2018. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1053811918302854>
- [23] S. Saxena, M. Funk, and D. Chisholm, “World health assembly adopts comprehensive mental health action plan 2013-2020,” *Lancet*, vol. 381, no. 9882, pp. 1970–1971, Jun. 2013, pMID: 23746771.
- [24] A. Galiana-Simal, P. Vecina-Navarro, P. Sánchez-Ruiz, and M. Vela-Romero, “Electroencefalografía cuantitativa como herramienta para el diagnóstico y seguimiento del paciente con trastorno por déficit de atención/hiperactividad,” *Rev. Neurol.*, vol. 70, no. 06, p. 197, 2020.
- [25] D. A. Pineda, F. Lopera, J. D. Palacio, D. Ramirez, and G. C. Henao, “Prevalence estimations of attention-deficit/hyperactivity disorder: differential diagnoses and comorbidities in a colombian sample,” *International Journal of Neuroscience*, vol. 113, no. 1, pp. 49–71, 2003.
- [26] L. J. Llanos Lizcano *et al.*, “Trastorno por déficit de atención e hiperactividad (tdah) en niños escolarizados de 6 a 17 años,” *Pediatría Aten. Primaria*, vol. 21, no. 83, pp. e101–e108, 2019.
- [27] M. E. Narad *et al.*, “Parent–teacher agreement on adhd symptoms across development,” *Psychological Assessment*, vol. 27, no. 1, p. 239, 2015.
- [28] T. Eslami, F. Almuqhim, J. S. Raiker, and F. Saeed, “Machine learning methods for diagnosing autism spectrum disorder and attention-deficit/hyperactivity disorder using functional and structural mri: A survey,” *Frontiers in Neuroinformatics*, vol. 14, p. 575999, Jan. 2021.
- [29] Y.-L. Yeh, T.-H. Hou, and W.-Y. Chang, “An intelligent model for the classification of children’s occupational therapy problems,” *Expert Systems with Applications*, vol. 39, no. 5, pp. 5233–5242, 2012.
- [30] G. V. Polanczyk, E. G. Willcutt, G. A. Salum, C. Kieling, and L. A. Rohde, “Adhd prevalence estimates across three decades: an updated systematic review and meta-regression analysis,” *International Journal of Epidemiology*, vol. 43, no. 2, pp. 434–442, Apr. 2014.
- [31] M. E. de la Viuda Suárez, J. C. Alonso Lorenzo, F. J. Ruiz Jiménez, and M. C. Luciano Soriano, “Assessing adhd symptoms in clinical public practice: Is a reliable final diagnosis possible?” *Aten. Primaria*, vol. 53, no. 3, p. 101945, Mar. 2021.
- [32] M. R. Arbabshirani, S. Plis, J. Sui, and V. D. Calhoun, “Single subject prediction of brain disorders in neuroimaging: Promises and pitfalls,” *NeuroImage*, vol. 145, p. 137 – 165, 2017, cited by: 667; All Open Access, Bronze Open Access, Green Open Access. [Online].

Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-84962787673&doi=10.1016%2fj.neuroimage.2016.02.079&partnerID=40&md5=02c435791465a7d077ad0db2d5ba2137>

- [33] J. D. Pastrana-Cortes, M. C. Maya-Piedrahita, P. M. Herrera-Gómez, D. Cárdenas-Peña, and A. A. Orozco-Gutierrez, “Interpretable diagnosis of adhd based on wavelet features and logistic regression,” in *Progress in Artificial Intelligence and Pattern Recognition*, Y. Hernández Heredia, V. Mi-líán Núñez, and J. Ruiz Shulcloper, Eds. Cham: Springer International Publishing, 2021, pp. 424–433.
- [34] C. J. Vaidya, X. You, S. Mostofsky, F. Pereira, M. M. Berl, and L. Kenworthy, “Data-driven identification of subtypes of executive function across typical development, attention deficit hyperactivity disorder, and autism spectrum disorders,” *Journal of Child Psychology and Psychiatry and Allied Disciplines*, vol. 61, no. 1, p. 51 – 61, 2020, cited by: 71; All Open Access, Green Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85072172828&doi=10.1111%2fjcpp.13114&partnerID=40&md5=2c19801a420c8a611573b09d2a121f06>
- [35] H. T. Tor, C. P. Ooi, N. S. Lim-Ashworth, J. K. E. Wei, V. Jahmunah, S. L. Oh, U. R. Acharya, and D. S. S. Fung, “Automated detection of conduct disorder and attention deficit hyperactivity disorder using decomposition and nonlinear techniques with eeg signals,” *Computer Methods and Programs in Biomedicine*, vol. 200, 2021, cited by: 93. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85099615028&doi=10.1016%2fj.cmpb.2021.105941&partnerID=40&md5=be182f5ba2f9cd1a27831fe3a7ded6dc>
- [36] E.-A. Paraschiv, M. Ianculescu, and A. Alexandru, “Bridging the gap: Deep learning eeg-based applications for schizophrenia classification and management,” vol. 109, 2024, Conference paper, p. 676 – 684, cited by: 0. [Online]. Available: https://www.scopus.com/inward/record.uri?eid=2-s2.0-85210073213&doi=10.1007%2f978-3-031-62502-2_76&partnerID=40&md5=6c97da2b0b743f44999242993d3daed3
- [37] G. Arji, L. Erfannia, S. alirezai, and M. Hemmat, “A systematic literature review and analysis of deep learning algorithms in mental disorders,” *Informatics in Medicine Unlocked*, vol. 40, 2023, cited by: 7; All Open Access, Gold Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85161681016&doi=10.1016%2fj.imu.2023.101284&partnerID=40&md5=b1a369fb778fd6fcb1a2623f0cc92eeb>
- [38] A. Ahmadi, M. Kashefi, H. Shahrokhi, and M. A. Nazari, “Computer aided diagnosis system using deep convolutional neural networks for adhd subtypes,” *Biomedical Signal Processing and Control*, vol. 63, p. 102227, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1746809420303578>
- [39] S. Zhang and D. Metaxas, “On the challenges and perspectives of foundation models for medical image analysis,” *Medical Image Analysis*, vol. 91, 2024, cited by: 35; All Open Access, Green Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85175172380&doi=10.1016%2fj.media.2023.102996&partnerID=40&md5=9e238dcfdad07138a235e852d56bf7d0>
- [40] D. Wang, X. Wang, L. Wang, M. Li, Q. Da, X. Liu, X. Gao, J. Shen, J. He, T. Shen, Q. Duan, J. Zhao, K. Li, Y. Qiao, and S. Zhang, “A real-world dataset and benchmark for foundation model adaptation in medical image classification,” *Scientific Data*, vol. 10, no. 1, 2023, cited by: 10; All Open Access, Gold Open Access, Green Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85169682108&doi=10.1038%2fs41597-023-02460-0&partnerID=40&md5=e491975ddc9a5c14fa6e033a2d878f30>
- [41] S. Abbaspourazad, O. Elachqar, A. C. Miller, S. Emrani, U. Nallasamy, and I. Shapiro, “Large-scale training of foundation models for wearable biosignals,” 2024, Conference paper, cited

by: 2. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85199807514&partnerID=40&md5=151326ca004a05961164e60923cad4a0>

- [42] L. Lim, A. Marquand, A. A. Cubillo, A. B. Smith, K. Chantiluke, A. Simmons, M. Mehta, and K. Rubia, "Disorder-specific predictive classification of adolescents with attention deficit hyperactivity disorder (adhd) relative to autism using structural magnetic resonance imaging," *PLoS ONE*, vol. 8, no. 5, 2013, cited by: 87; All Open Access, Gold Open Access, Green Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-84877826499&doi=10.1371%2fjournal.pone.0063660&partnerID=40&md5=e31429216c7db29697c5c53ddac19103>
- [43] H. Hart, K. Chantiluke, A. I. Cubillo, A. B. Smith, A. Simmons, M. J. Brammer, A. F. Marquand, and K. Rubia, "Pattern classification of response inhibition in adhd: Toward the development of neurobiological markers for adhd," *Human Brain Mapping*, vol. 35, no. 7, p. 3083 – 3094, 2014, cited by: 98; All Open Access, Green Open Access, Hybrid Gold Open Access. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-84902213440&doi=10.1002%2fhbm.22386&partnerID=40&md5=d65b9f9465a4be890498a36781cd6bb2>